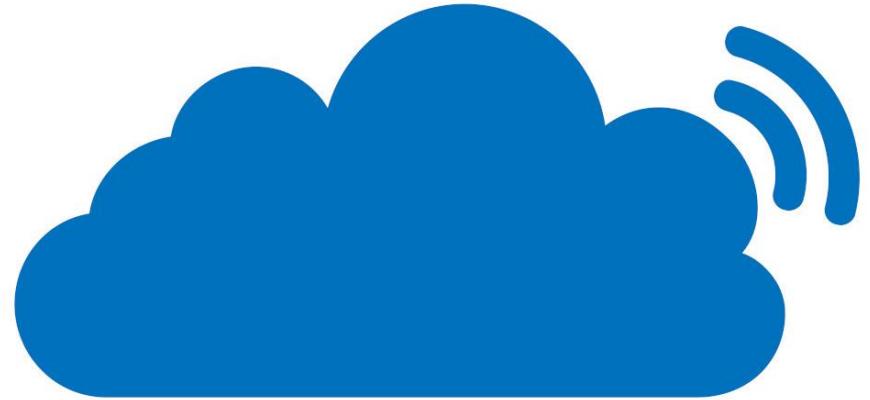


AIoT = AI + IoT

Juan Félix Mateos
juanfelixmateos@gmail.com
jfmateos@educa.madrid.org
Abril 2022



¿Compartimos una red IoT?

IoT open Tech

Hilos argumentales

El fracaso forma parte del aprendizaje

Procomún → Modelo de gobernanza para el bien común.

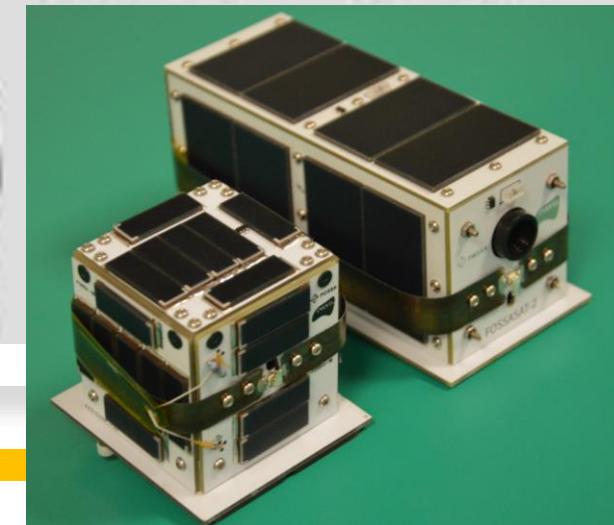
Transferencia de conocimiento → Aprendizaje entre iguales

Automatización del trabajo; desempleo y cualificación

El ser humano es impresionante; cada uno de vosotros sois excepcionales



Forbes
**30
30**





Real Time Live
Tracking



Geo-fence Alert



SOS Button





Cattle Tracker Tag





Temp



Humidity



Density



Time

Guaranteed Fire Safety of All Buildings

Provide a total solution of whole building fire prevention and evacuation. Including plan and install the sensors and HEX Dynamic Evacuation Signage Lights in the sites.

[SYSTEM FEATURES](#)

LEARN MORE



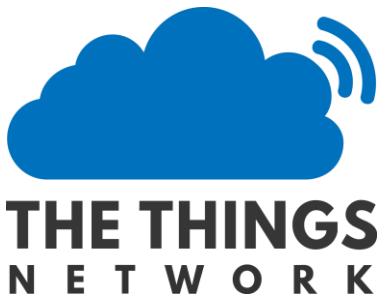












SEGURIDAD Y SOLDADURA



Riesgos

- **Químicos**

- Plomo nunca más
- Rosin (Colofonía) ¡Ojo con asmáticos!

- **Térmicos**

- Quemarse (poca importancia salvo que afecte a los ojos)

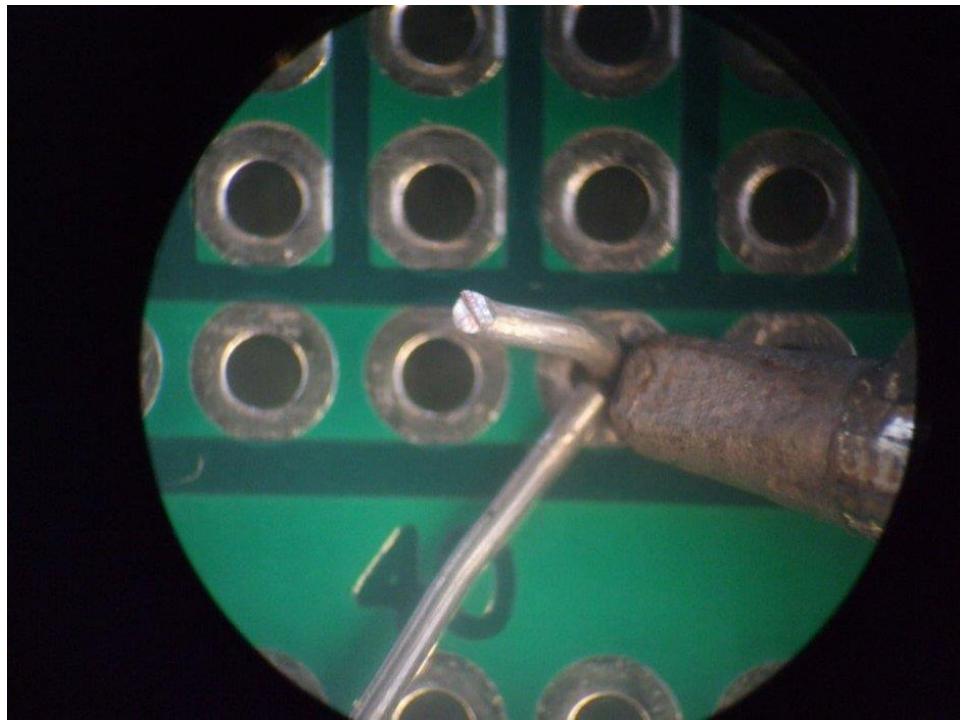
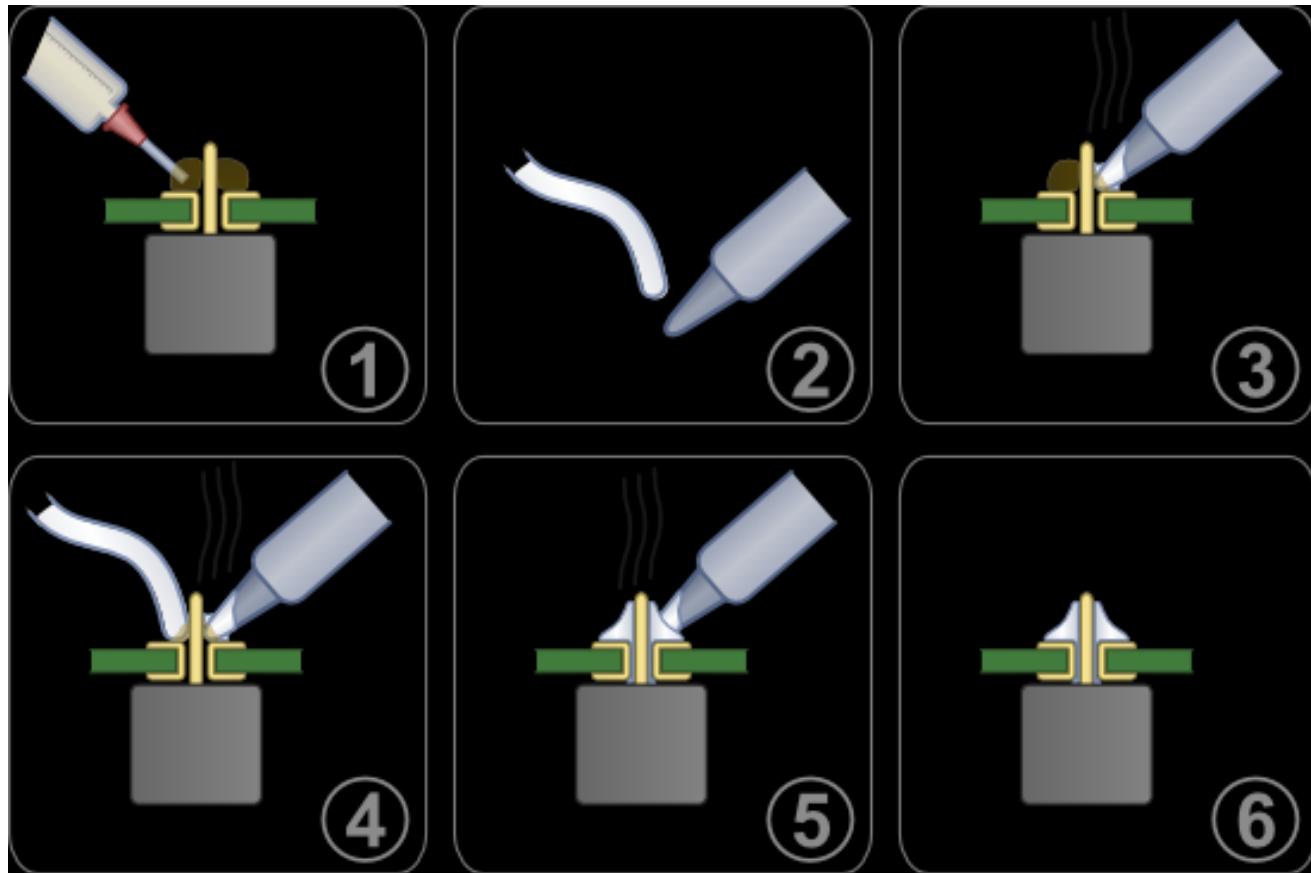
- **Eléctricos**

- Quemar el cable del soldador → Salta el magnetotérmico y susto
- No usar pulseras anti-estáticas → Estorban

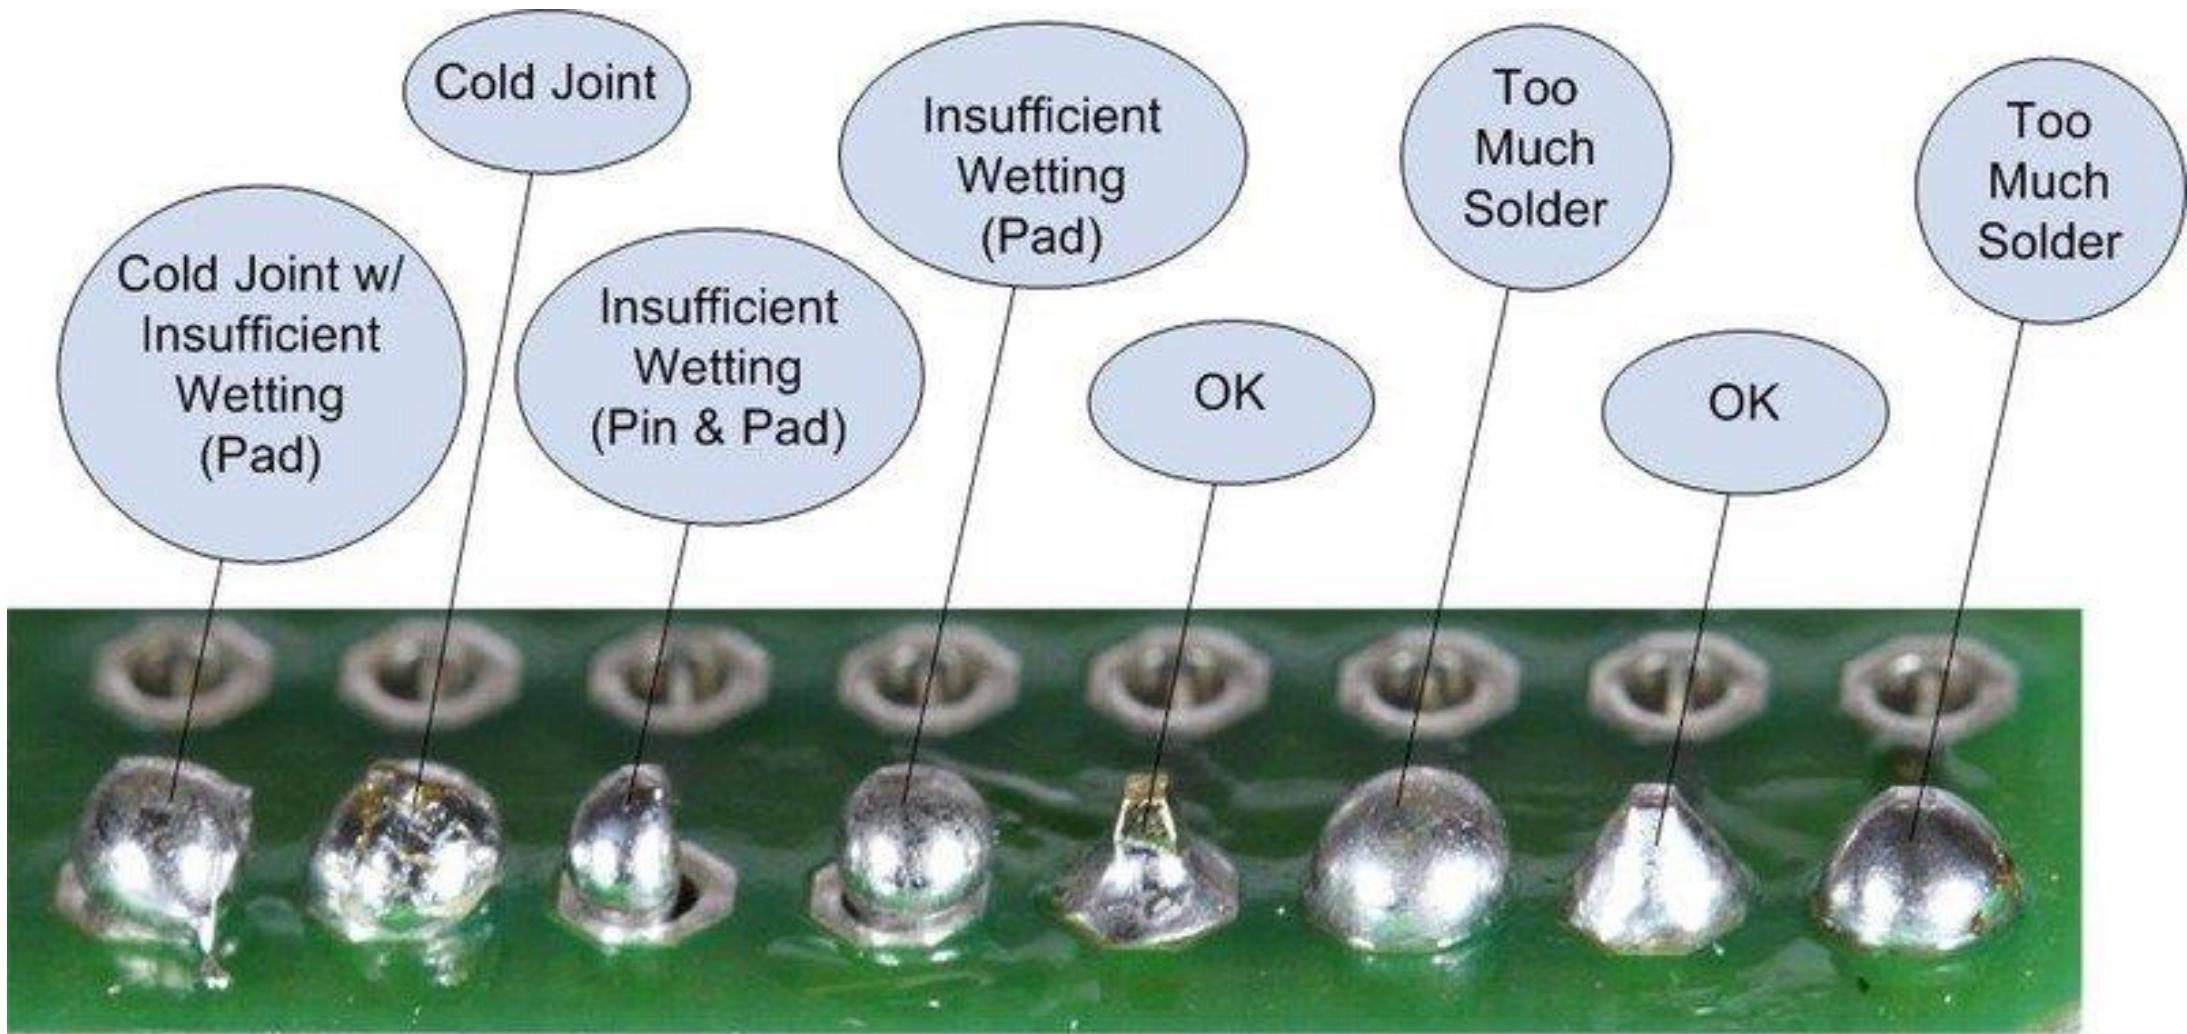
- **Mecánicos**

- Punta del soldador → Pinchar al compañero

¿CÓMO SOLDAR?

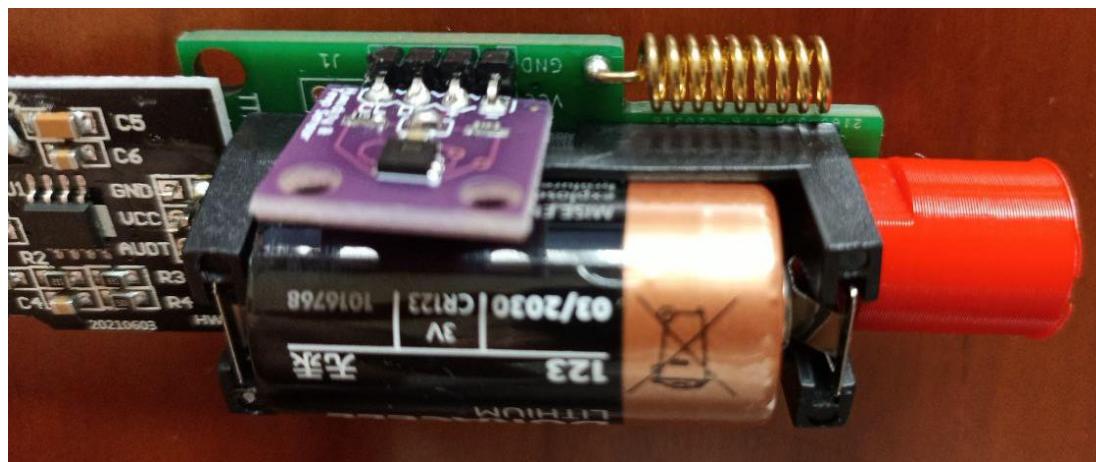


SOLDADURA CORRECTA

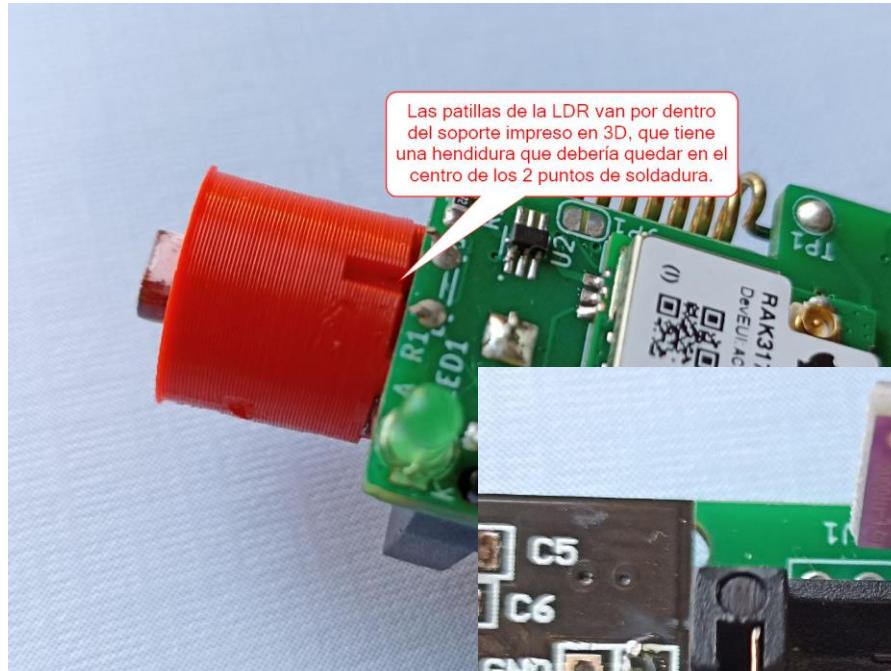


TTNMAD_PLANT

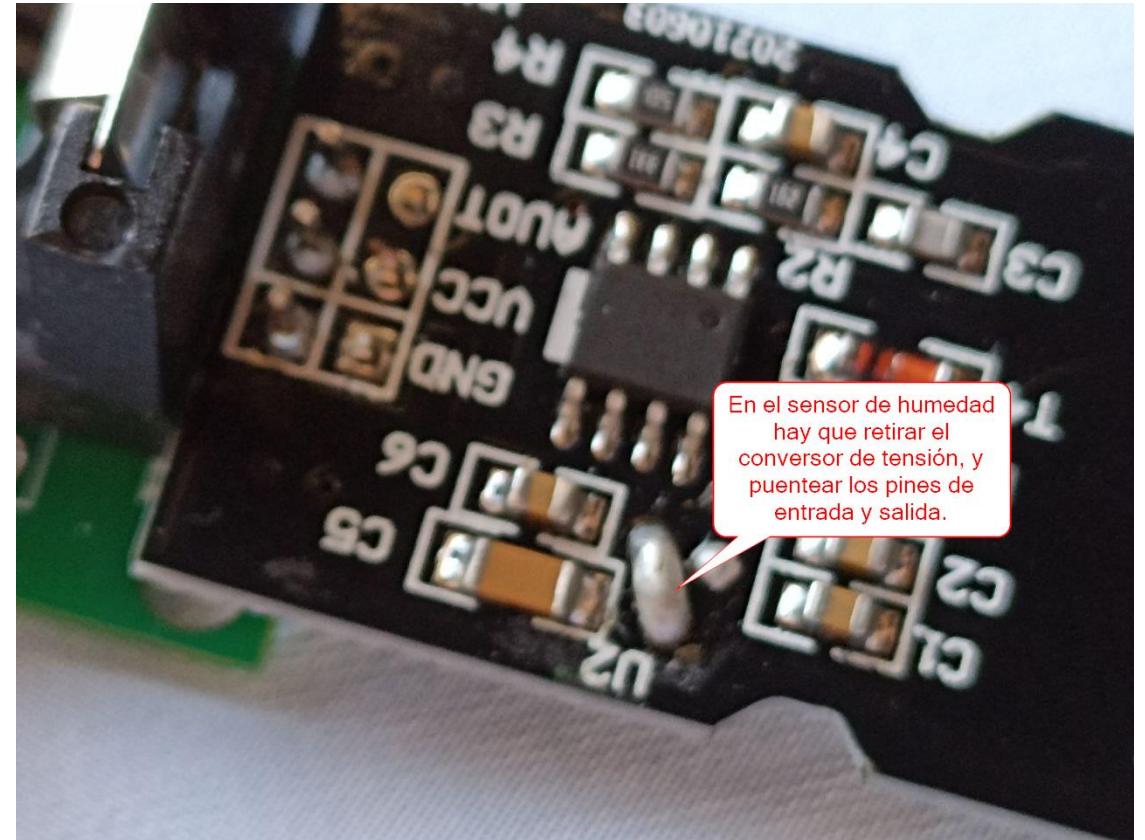
C1, C2, C4: 100n
R2: 6k8 = 6.8k (682)
R3: 220ohm (221)
R4: 10k (103)



TTNMAD_PLANT: Detalles soldadura



TTNMAD_PLANT: Otros detalles



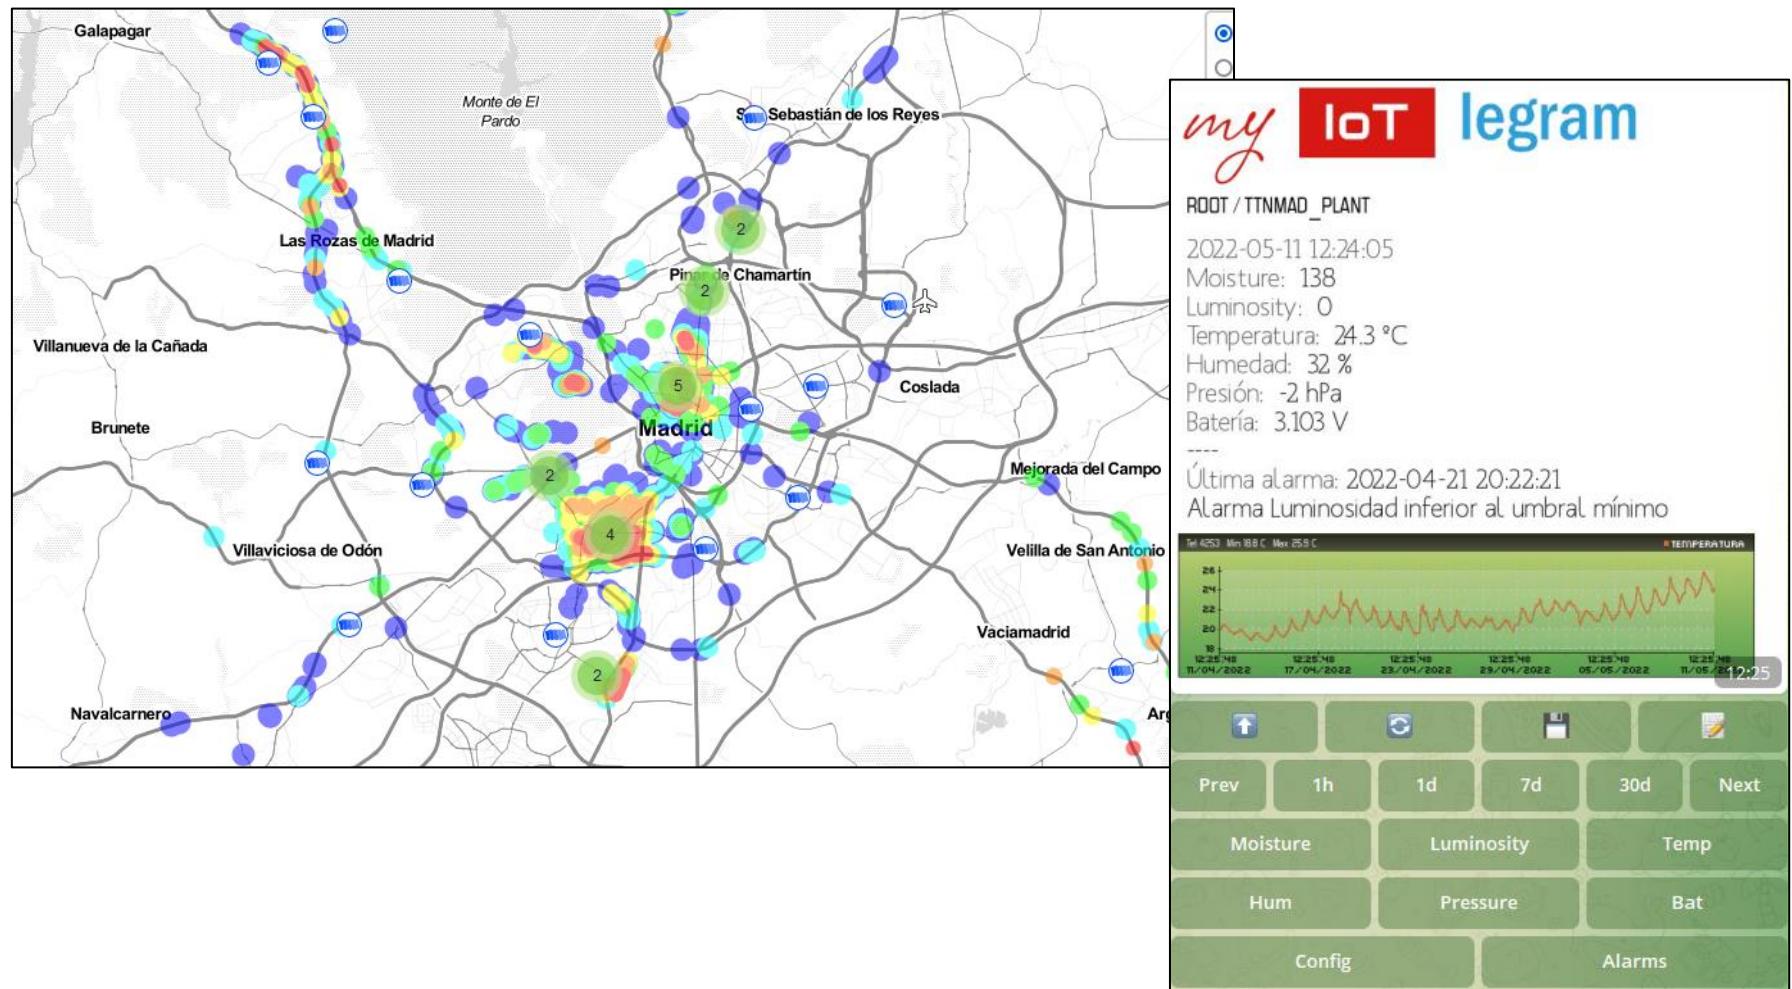
Cuestiones prácticas 1/2

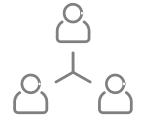
- Obtención de los materiales
 - Proveedores locales
 - Molukas, IoTTotal...
 - Proveedores globales
 - Mouser, Rsonline...
 - Aliexpress / Amazon
- Obtención de las herramientas
 - Mesa caliente vs Soldador aire caliente
 - Programador ST-Link
- PCB y Stencil
 - The Things Network Madrid
 - Fabricación propia - JLCPCB



Cuestiones prácticas 2/2

- Cobertura
 - ttnmapper.org
 - Gateways
 - Monitorización
 - myIoTgram
 - Administrador
 - Observador

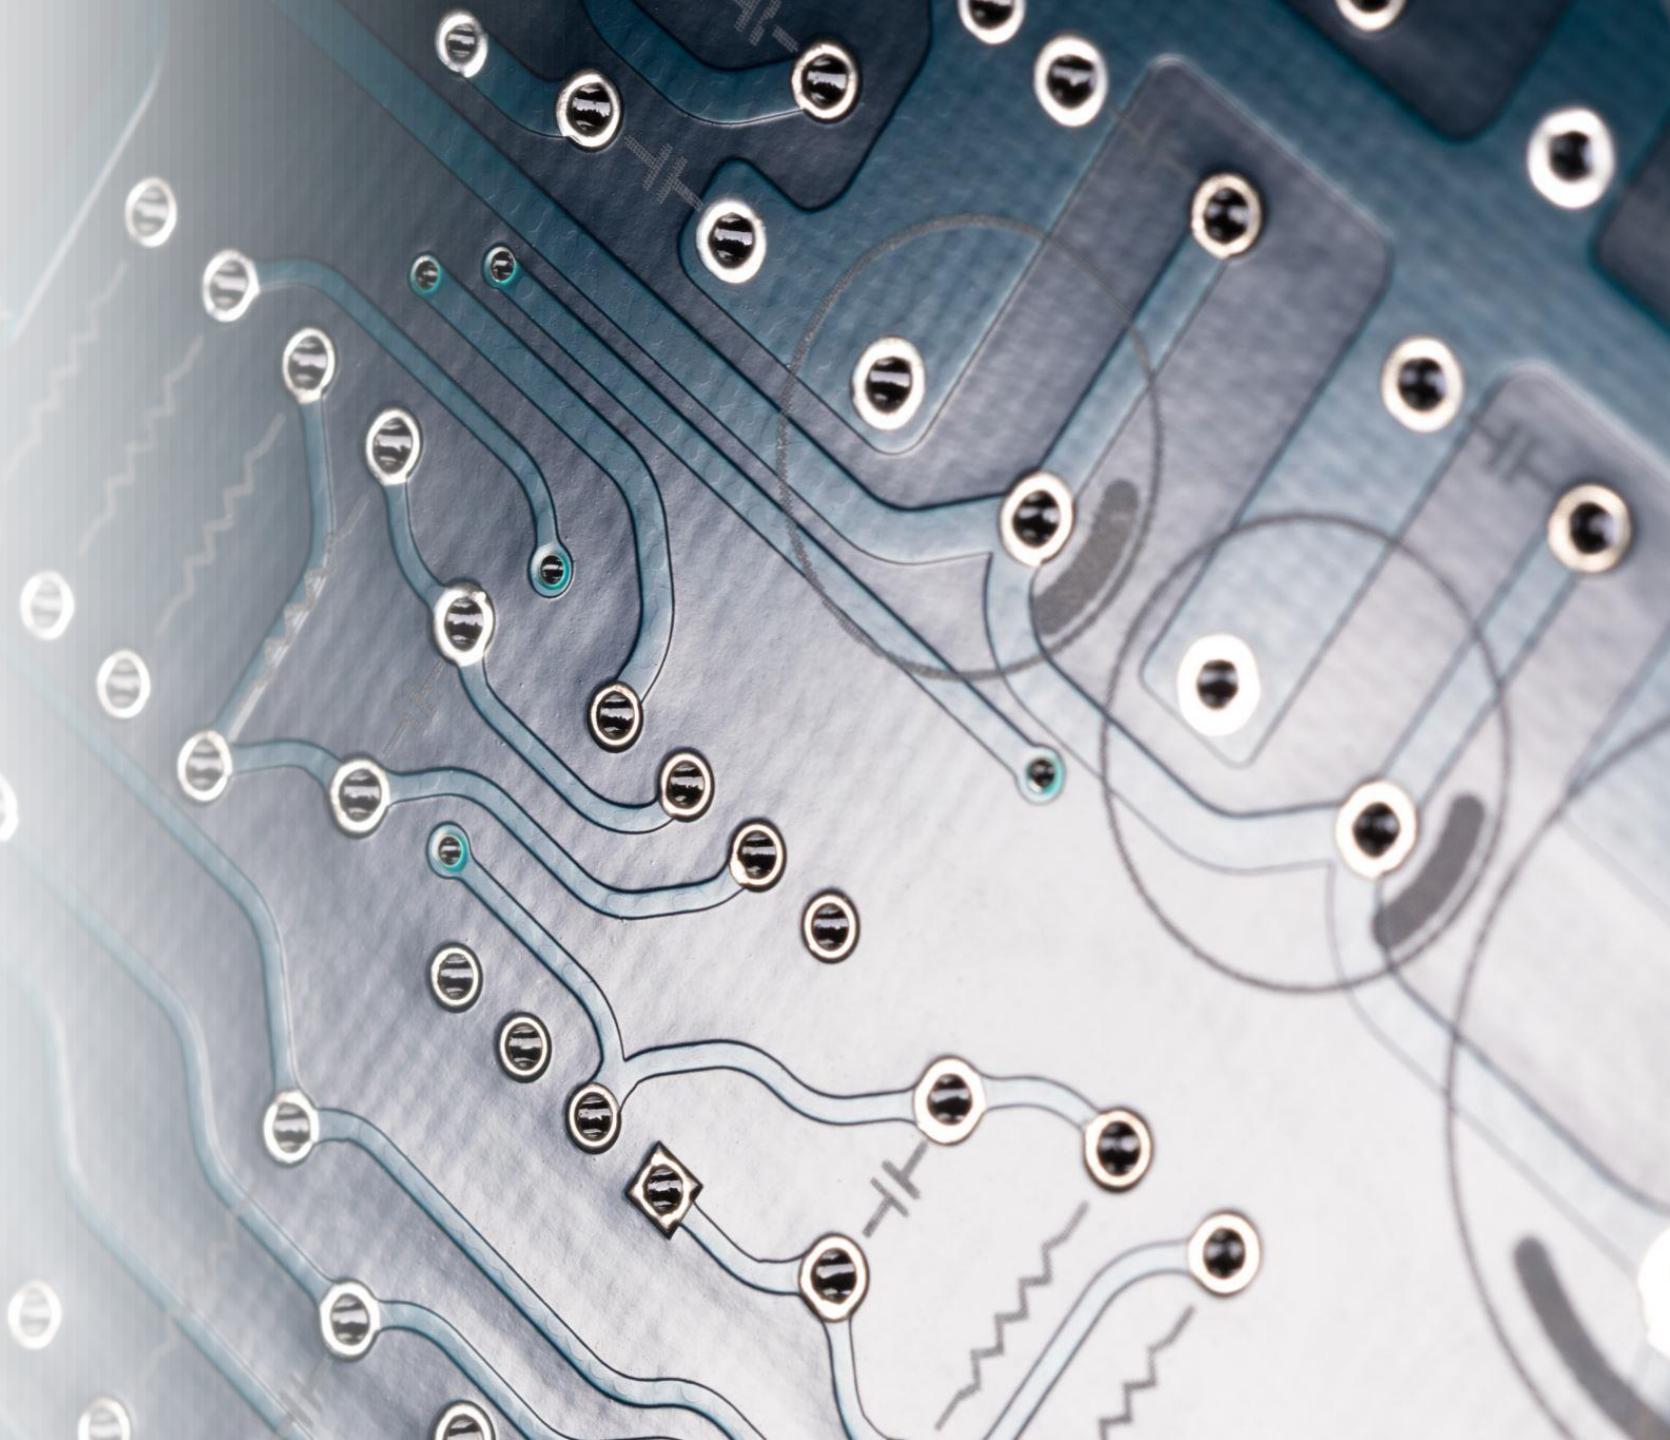




Inteligencia artificial

*Juan Félix Mateos
Noviembre 2021*

¿Qué es la
Inteligencia
Artificial?



Kasparov
vs
Deep Blue
1996: Gana Kasparov
+3 =2 -1
1997: Gana Deepblue
+2 =3 -1



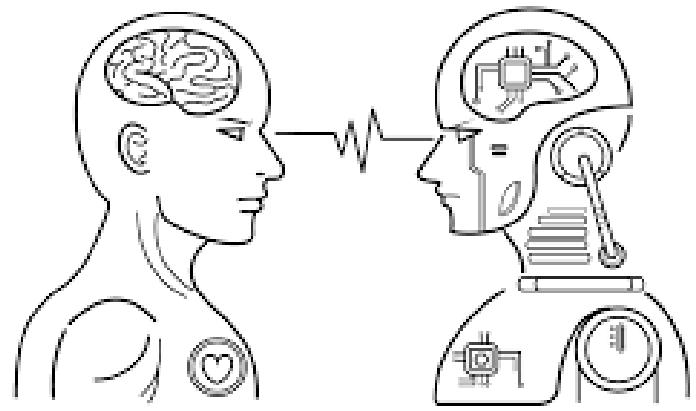
AlphaGo 2016



Otros hitos de la AI



- 2005: DARPA Grand Challenge
- 2011: AI gana el programa Jeopardy!
- 2012: AI aprende a reconocer imágenes de gatos de forma no supervisada
- 2015: AI supera a humanos reconociendo una colección de 1000 imágenes
- 2015: Arte generado por AI imitando a pintores ilustres
- 2019: Servicio de taxi autónomo en Phoenix/Arizona



Inteligencia humana

- Analizar y razonar
- Resolver problemas
- Alcanzar objetivos
- Comunicar, colaborar y convencer
- Conciencia (emociones, intuición, imaginación)

Inteligencia artificial

- Capacidad de las máquinas para simular y mejorar la inteligencia humana

Inteligencia artificial

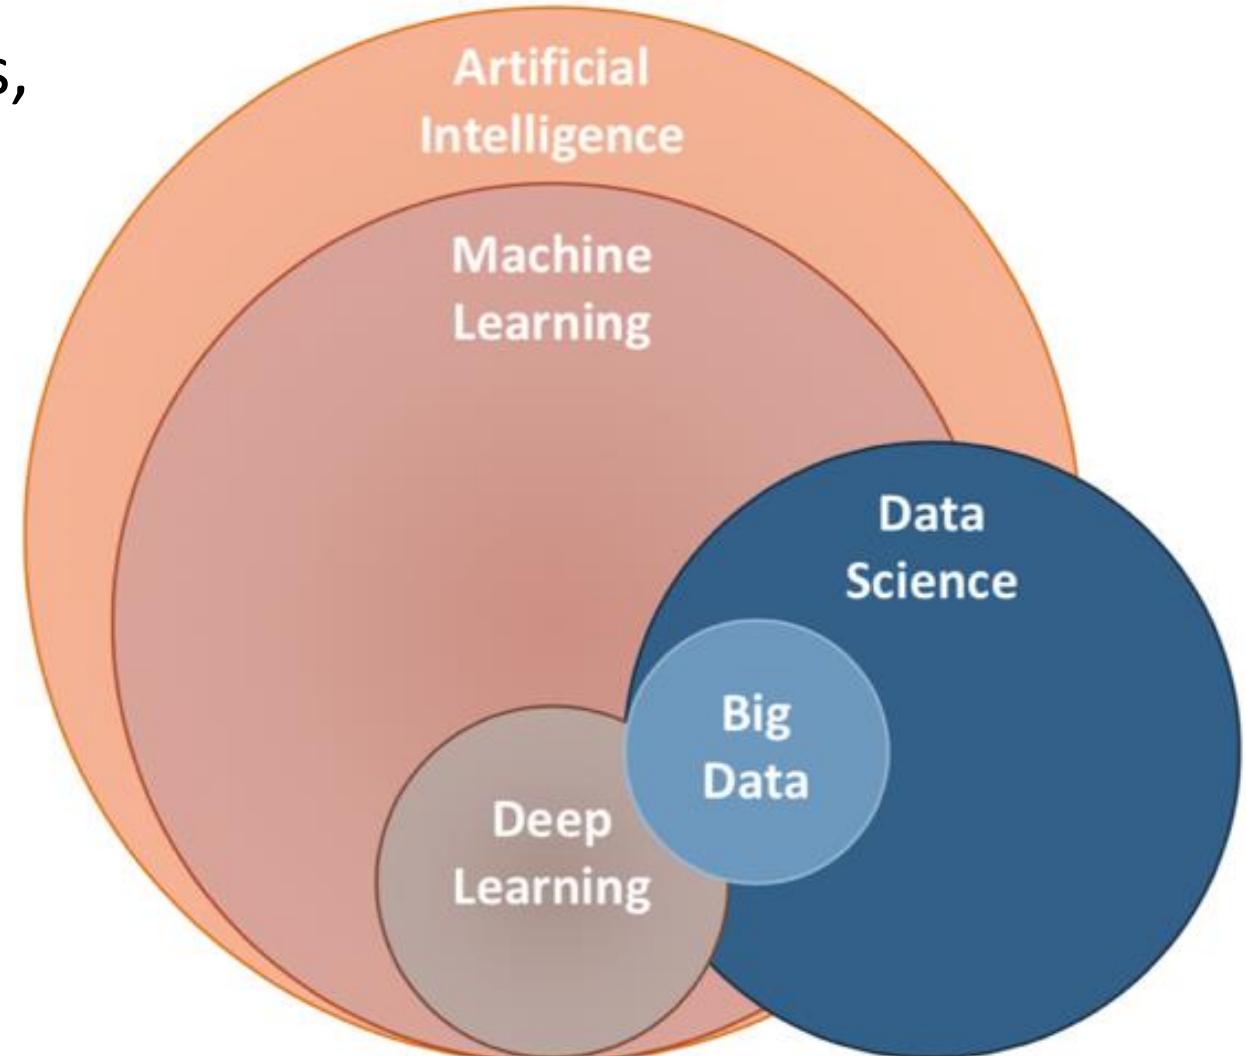
Programa que puede leer sensores, tomar decisiones, actuar y adaptarse.

Machine learning

Algoritmos que son capaces de mejorar con el tiempo a medida que procesan mayor cantidad de datos

Deep learning

Subtipo de Machine learning que utiliza redes neuronales multicapa



AI is **not new**, it's been around for a loong time

Mathematical Statistics



Artificial Intelligence

Soy Gauss, un matemático alemán, que resolvió problemas que se usan hoy en AI



1700's

1950's

1960's

1970's

1980's

1990's

2000's

2010's

Today

Future

1943 – The first ANN

1955 – Official term and academic recognition

1969 – Backpropagation

1985 – Rediscovery of Backprop

1958 – Rosenblatt's Perceptron

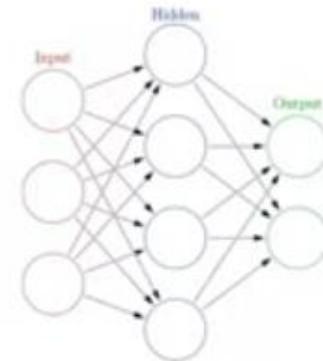
Machine Learning

A Bayesian Approach to Filtering Junk E-Mail
Mohsen Salami¹ Susan Dumais² David Heckerman² Eric Horvitz²
¹Computer Science Department, Stanford University, Stanford, CA 94305-8510
salami@cs.stanford.edu
²Microsoft Research, Redmond, WA 98052-6000
jdumais, dhbeck, ericvh@Microsoft.com

Abstract
In addressing the growing problem of junk E-mail in the Internet, we introduce methods for the automated classification of filters to eliminate such unwanted messages from a user's mail stream. By casting this problem as a probabilistic graphical model, we are able to make use of probabilistic learning methods to automatically train a set of differentiable classification rules to produce a high-quality filter. While this approach is attractive, we have found that for constructing domain-specific classifiers, we often find it is sufficient to build a set of simple decision rules to achieve much better accuracy than filters. Finally, we show the efficacy of such filters in a real world usage scenario, arguing that this technology is mature enough for deployment.

contains offensive material (such as graphic pornography), there is often a higher cost to users of actually reading this mail than simply the time to move out the junk. Early junk mail was usually sent via direct mail or electronic mail. In the early storage stages, especially at large sites with thousands of users who may all be getting duplicate copies of the same junk mail. As a result of this growing problem, automated methods for filtering such junk from legitimate E-mail are becoming necessary. Indeed, many commercial products are now available which allow users to build such a set of rules to filter their mail. This article, however, is presented at a low level. First, systems that require users to hand-build a rule set to detect junk mailer than these users are likely enough to be able to construct robust rules. Moreover, as the nature of E-mail itself changes, these rules will need to be

Deep Learning



2012 – AlexNet wins ImageNet

2013 - Today: Deep Learning is applied almost everywhere!

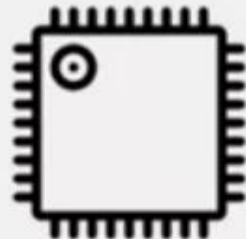
Por qué está de moda la AI ahora

1



Data availability

2



Computational power

3



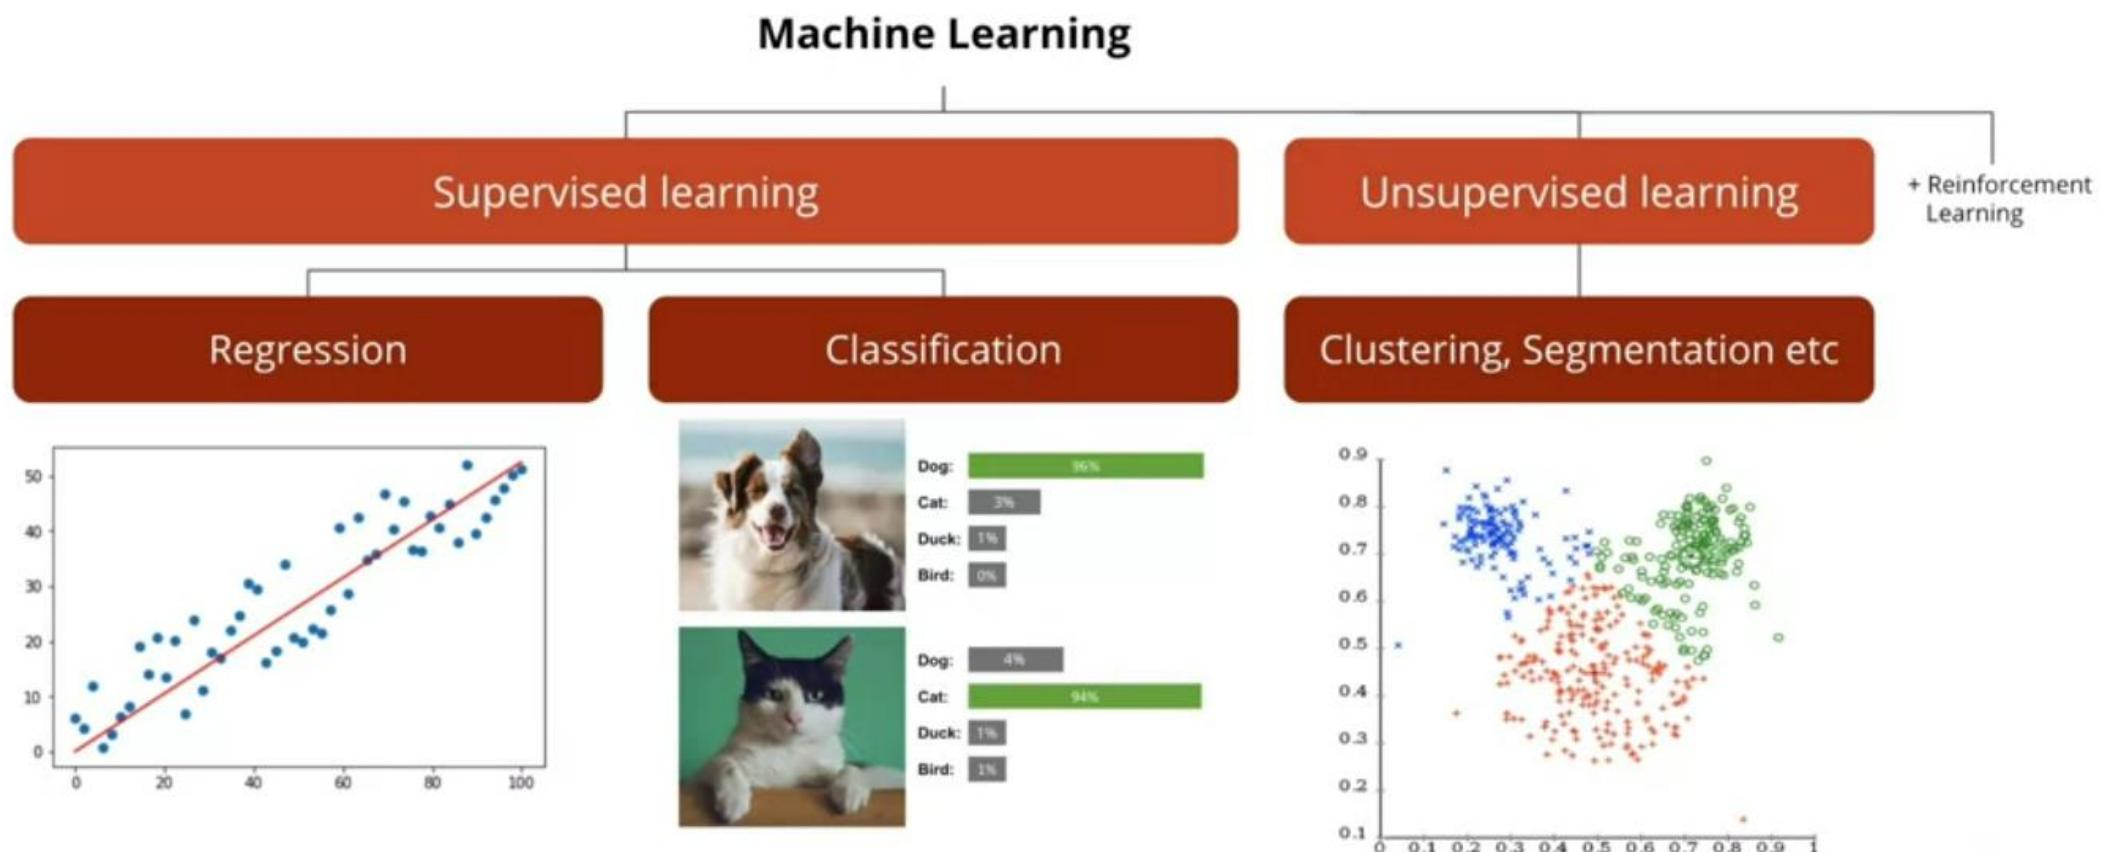
Algorithm advancements

4



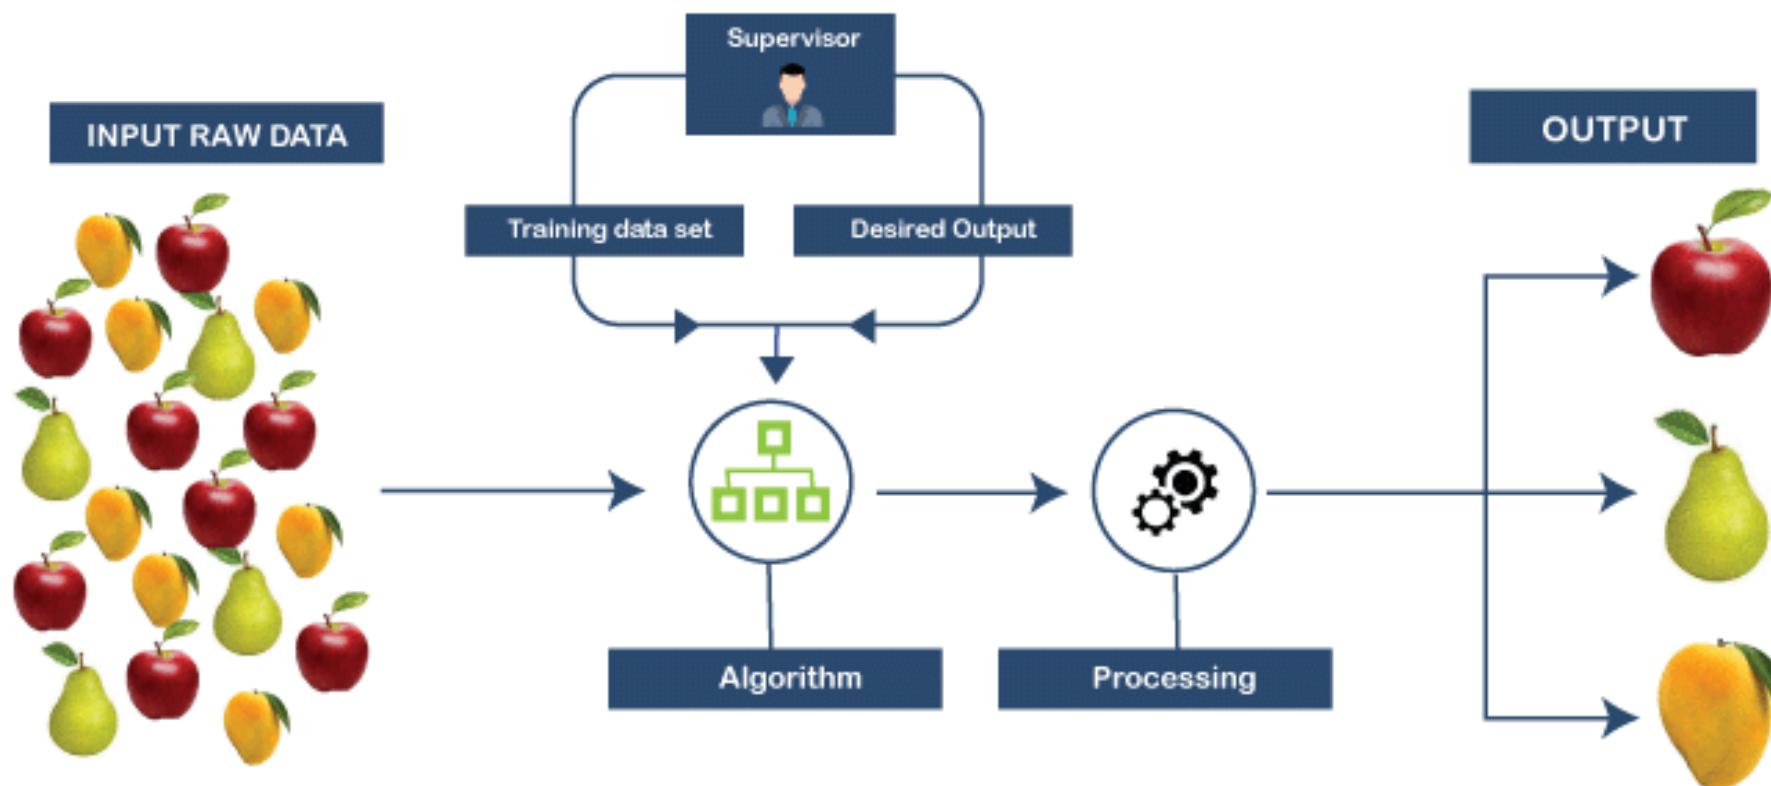
Broad public interest

Categorías de AI

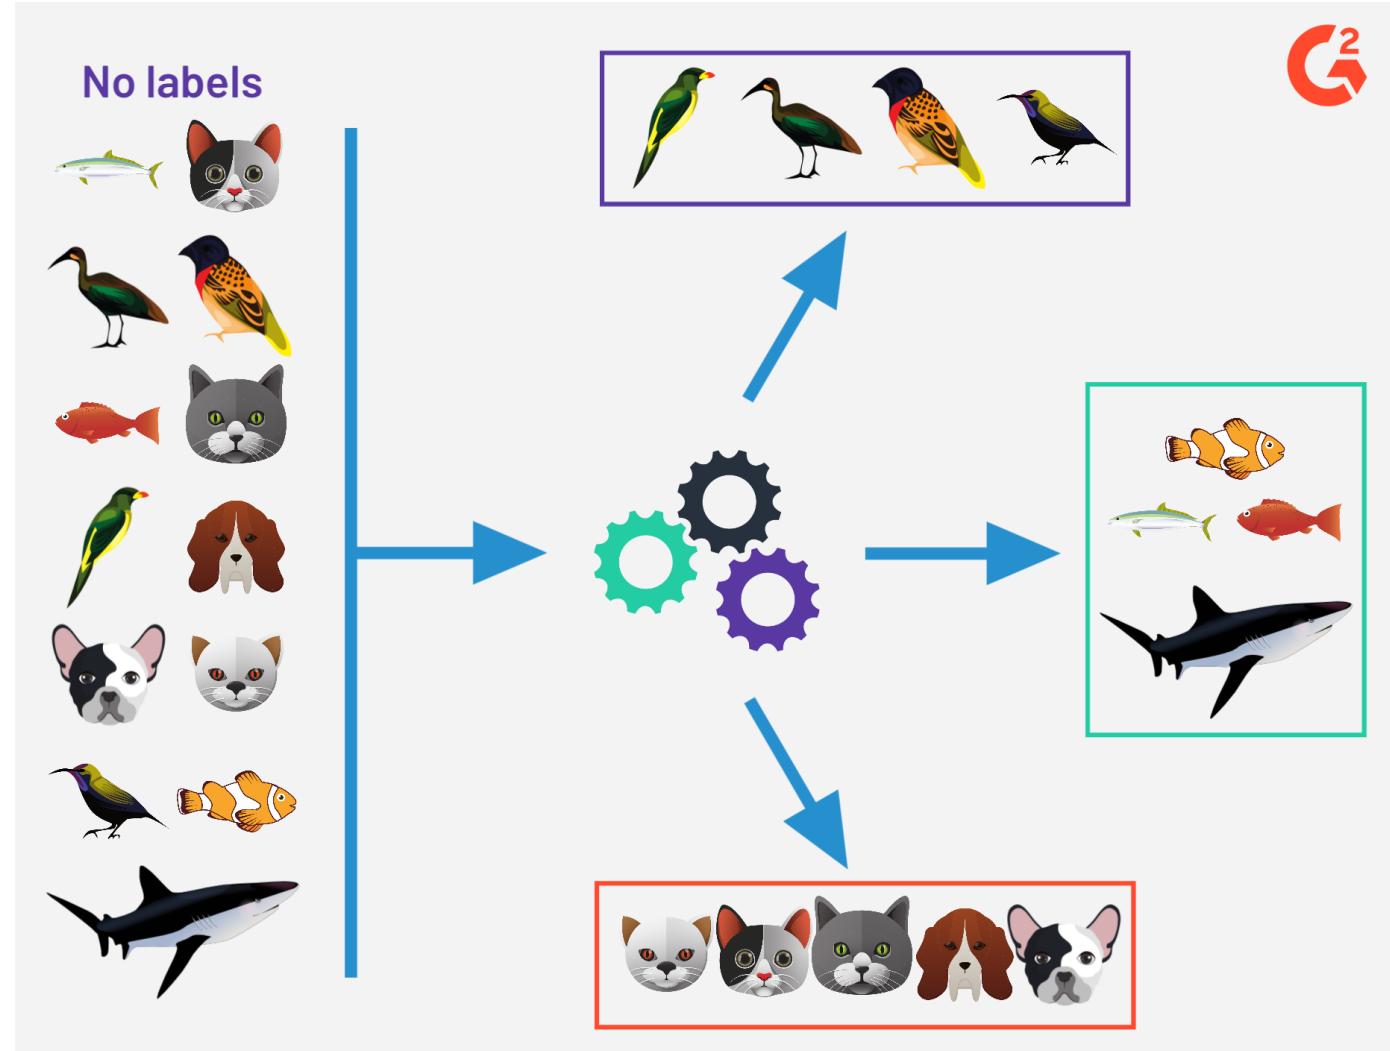


Aprendizaje supervisado

SUPERVISED LEARNING



Aprendizaje no supervisado





Steering: -0,05

Aprendizaje por refuerzo

https://youtu.be/VMp6pq6_QjI

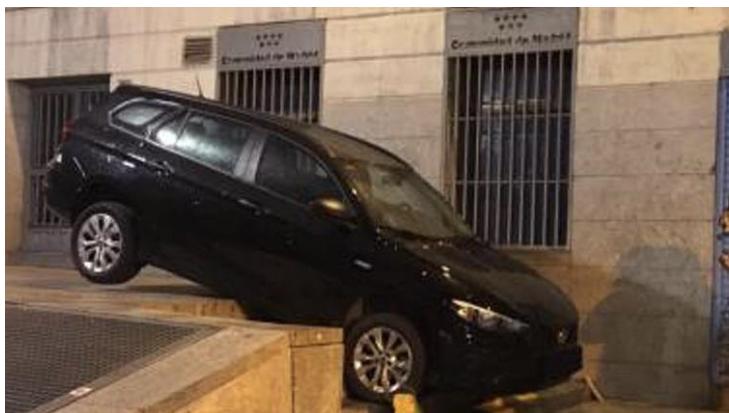
A.I. teaches itself to drive in Trackmania



Algoritmos genéticos

<https://youtu.be/a8Bo2DHrrow>

Peligros de la Inteligencia artificial

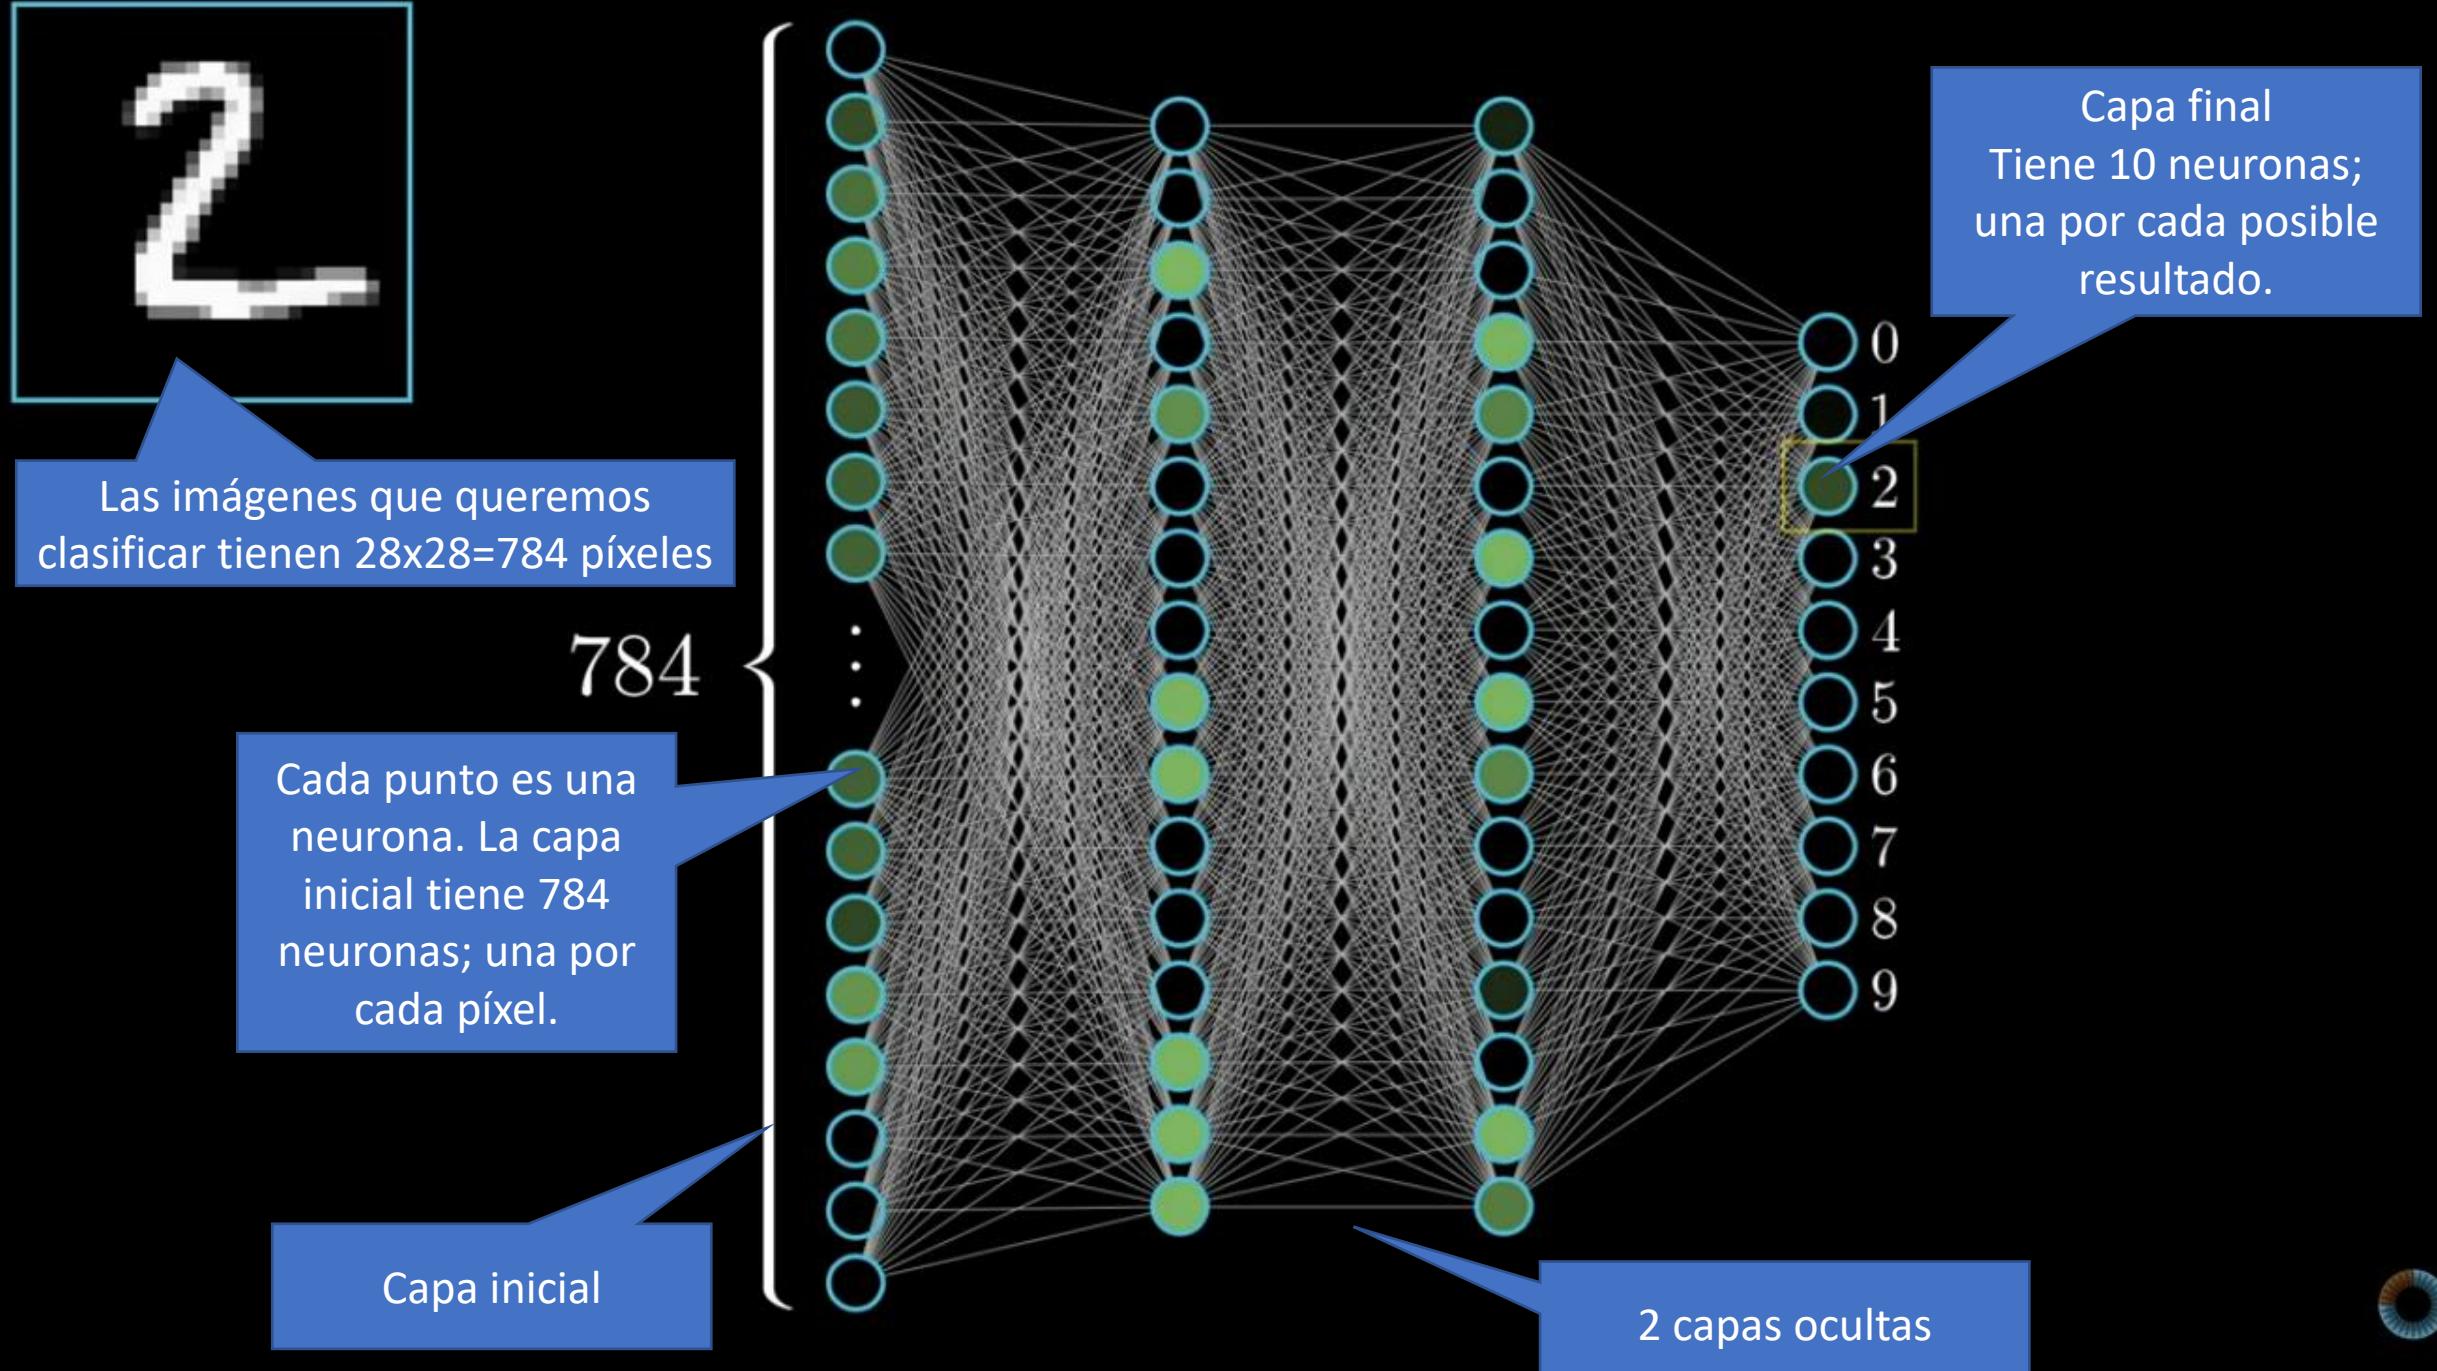


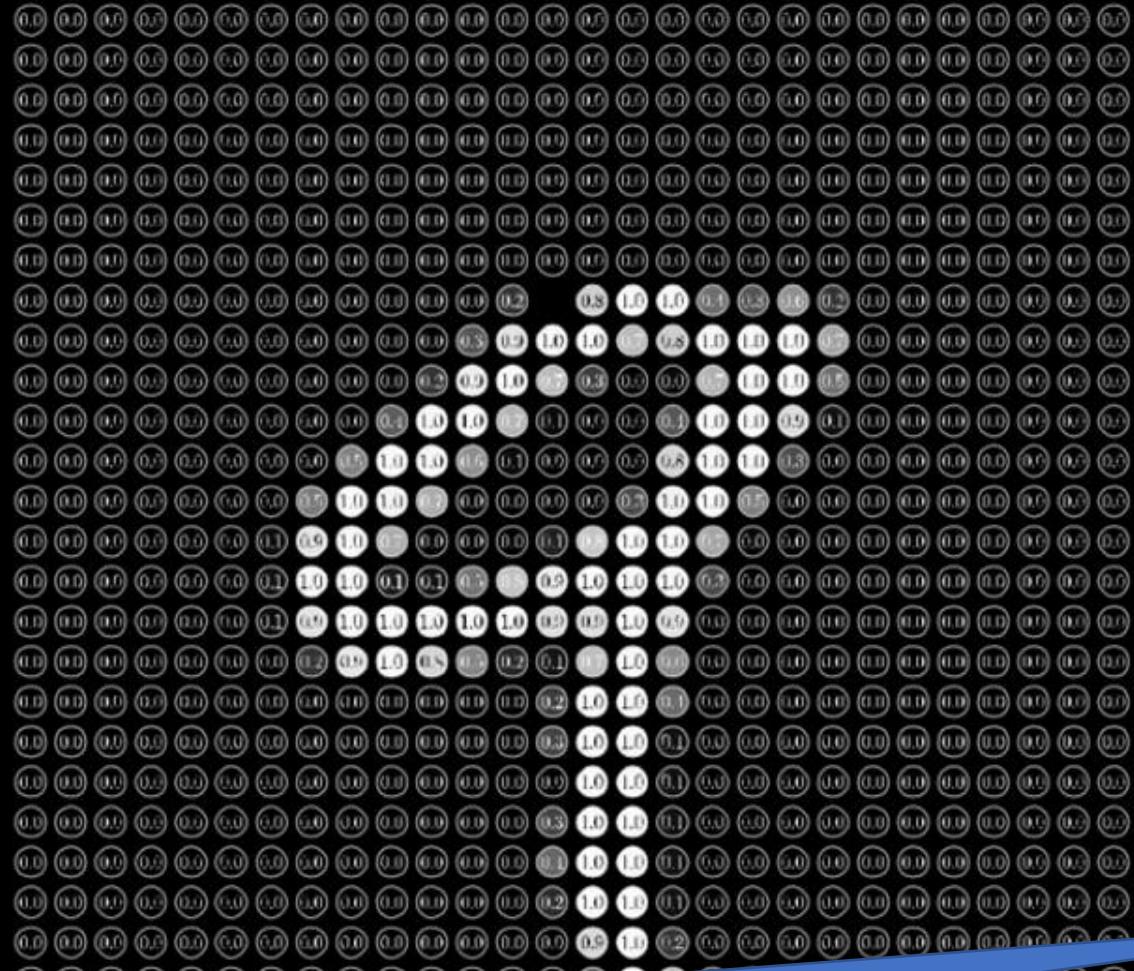
- **Dataísmo:** Confiar más en las máquinas que en nosotros mismos.
 - Un VTC se tira por unas escaleras siguiendo las instrucciones del GPS
 - Una niña golpeada por un bate de béisbol
- **Sesgo:** Los datos de entrenamiento tienen escondidos sesgos que se perpetúan en las predicciones, provocando discriminación
 - El sistema de reclutamiento de Amazon favorecía a los hombres porque se había entrenado con más currículos de hombres
- **Determinismo:** Los algoritmos se entrena con datos del pasado y hacen inferencias sobre el futuro.
 - Amazon siempre me recomendará libros del mismo tipo. No me permitirá ampliar mis horizontes.
- **Deep fake:** Imágenes, videos o voces generadas artificialmente (Facestar).

Deep Learning

Redes neuronales

<https://youtu.be/aircAruvnKk>





$$28 \times 28 = 784$$

0.58

“Activation”

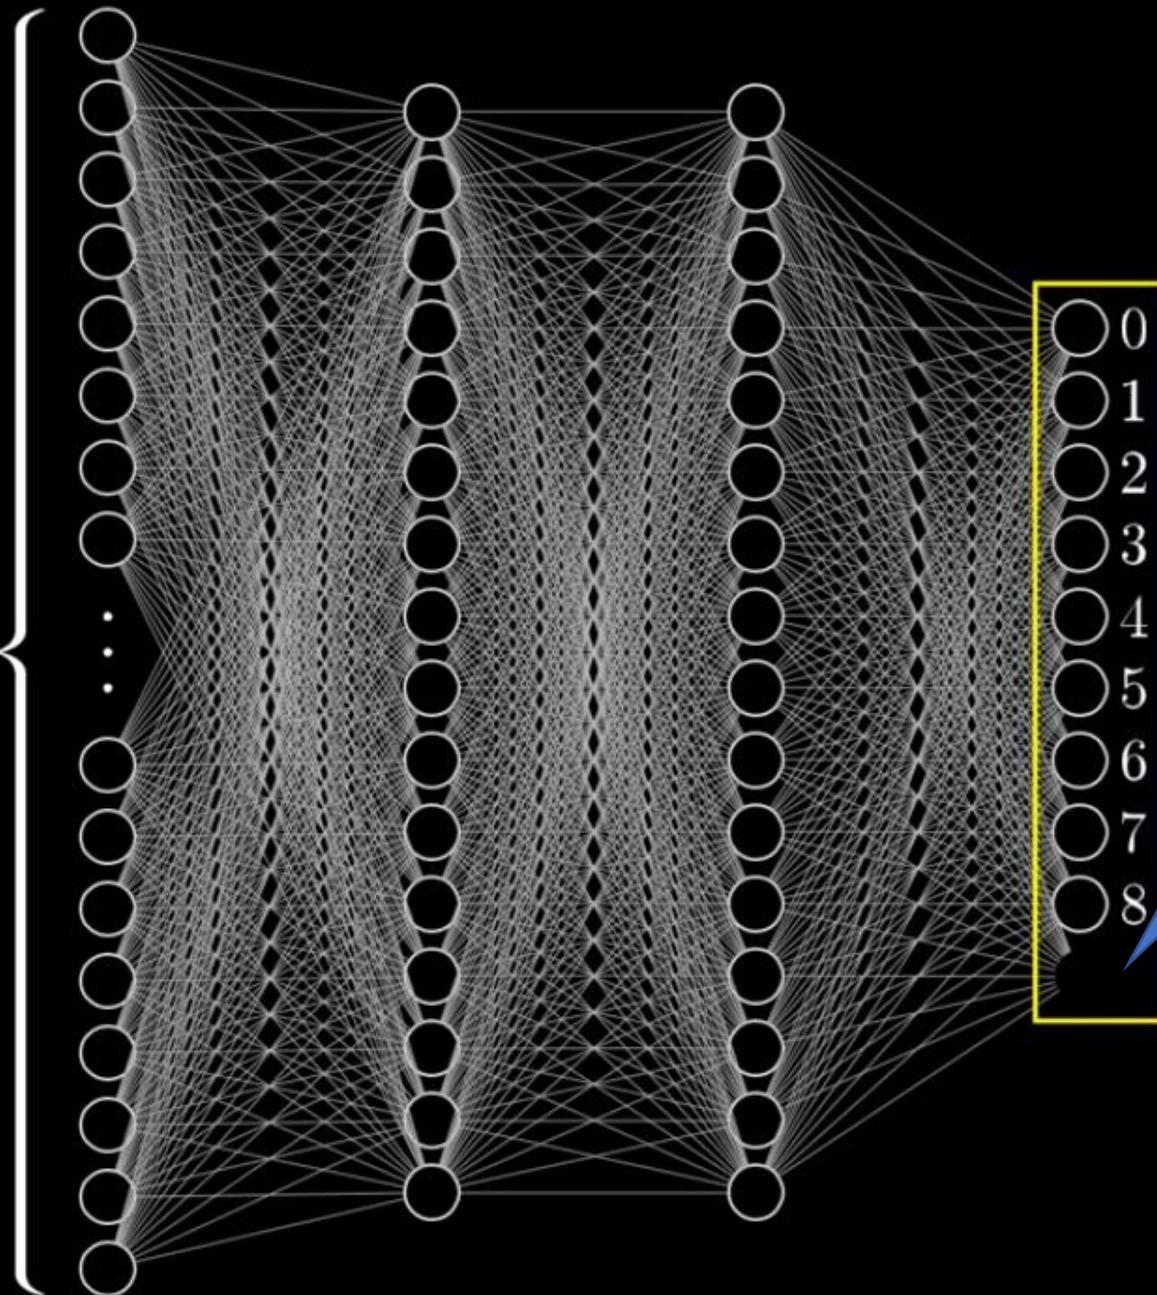
En la capa inicial, el valor de activación corresponde al nivel de intensidad de cada pixel

Una feature o característica, es cada una de las propiedades con las que queremos alimentar el modelo. En este ejemplo, tenemos una sola feature, que es el nivel de intensidad de cada pixel.





784



En la capa final, el valor de activación corresponde a la probabilidad de que la imagen corresponda a cada dígito

0.97 9



¿Y las capas
intermedias ocultas?
¿Qué hacen?



“Hidden layers”

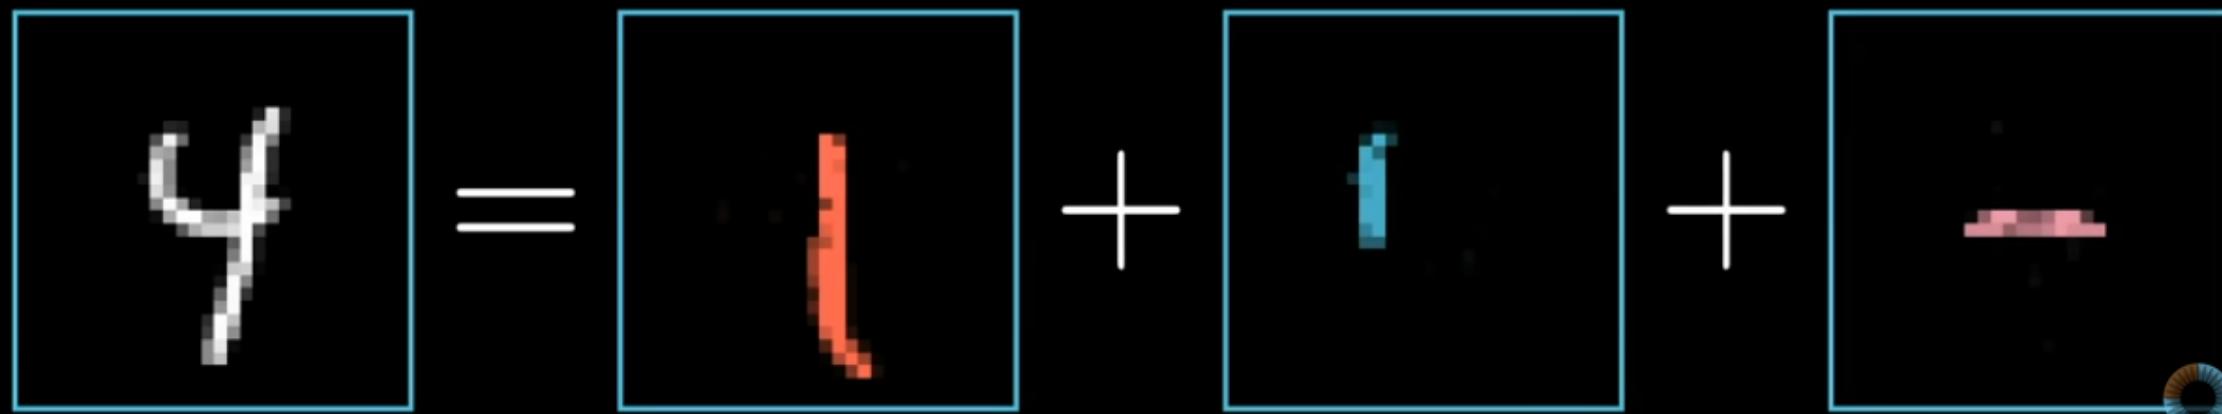
784

Los valores de activación
de las neuronas de cada
capa, provocan que se
activen ciertas neuronas
de la capa siguiente...
pero ¿cómo?



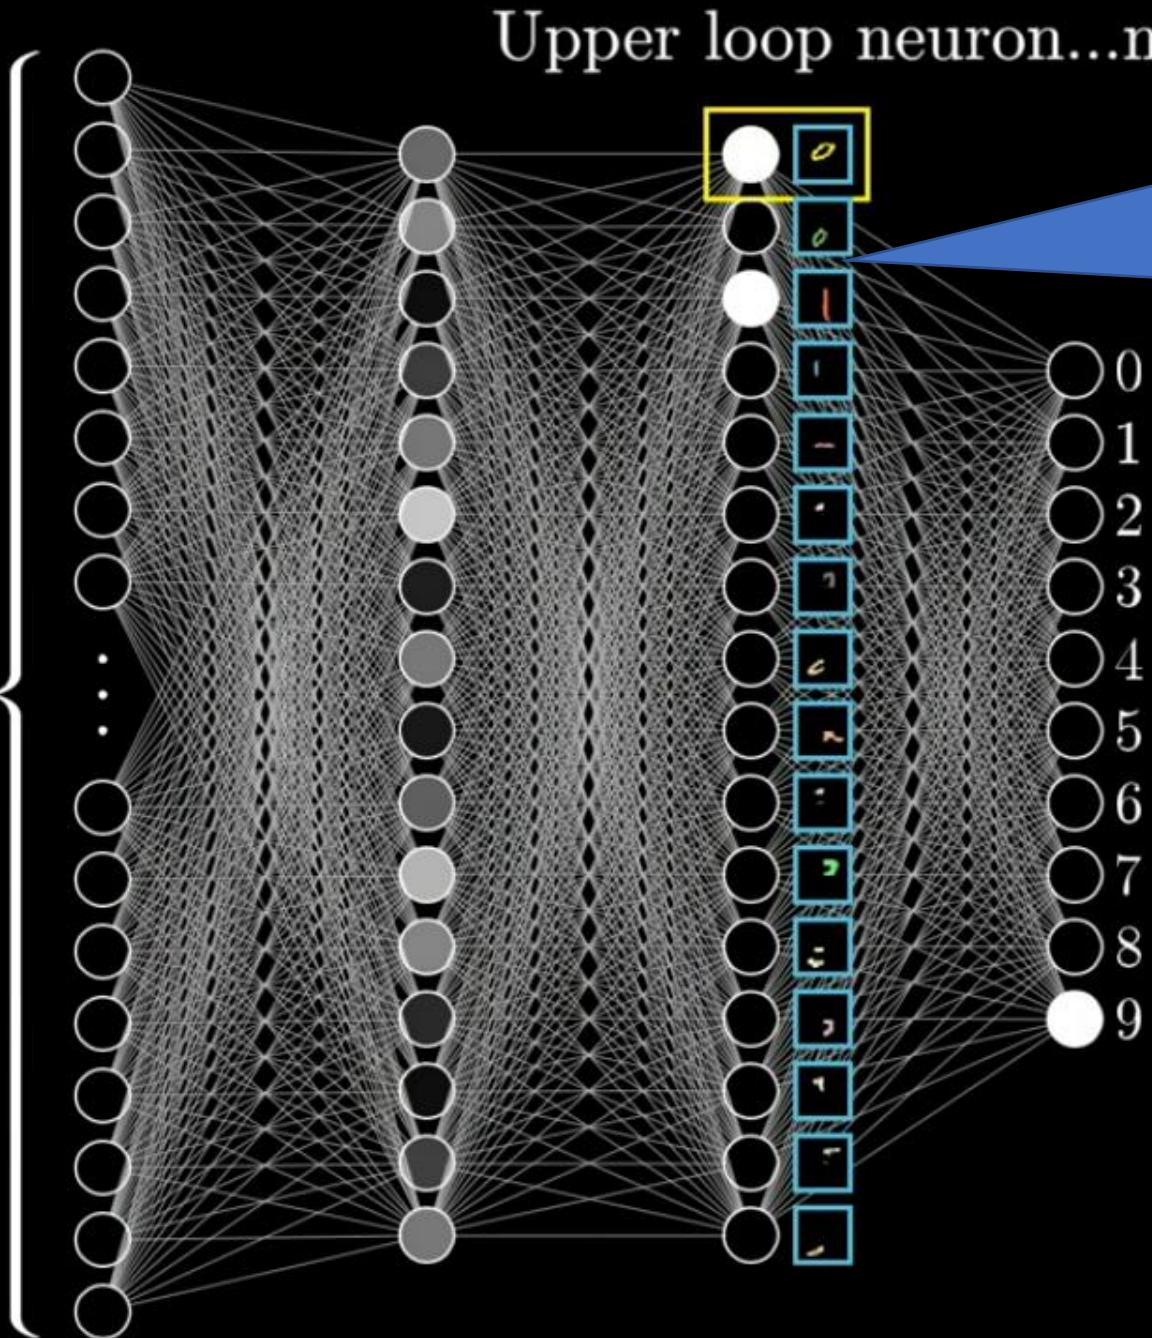


Cada número se puede descomponer en trazos básicos





784

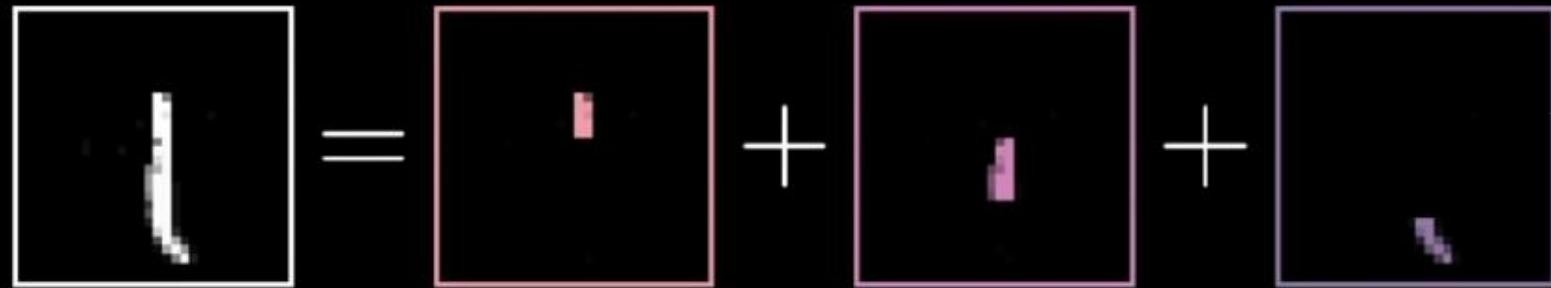
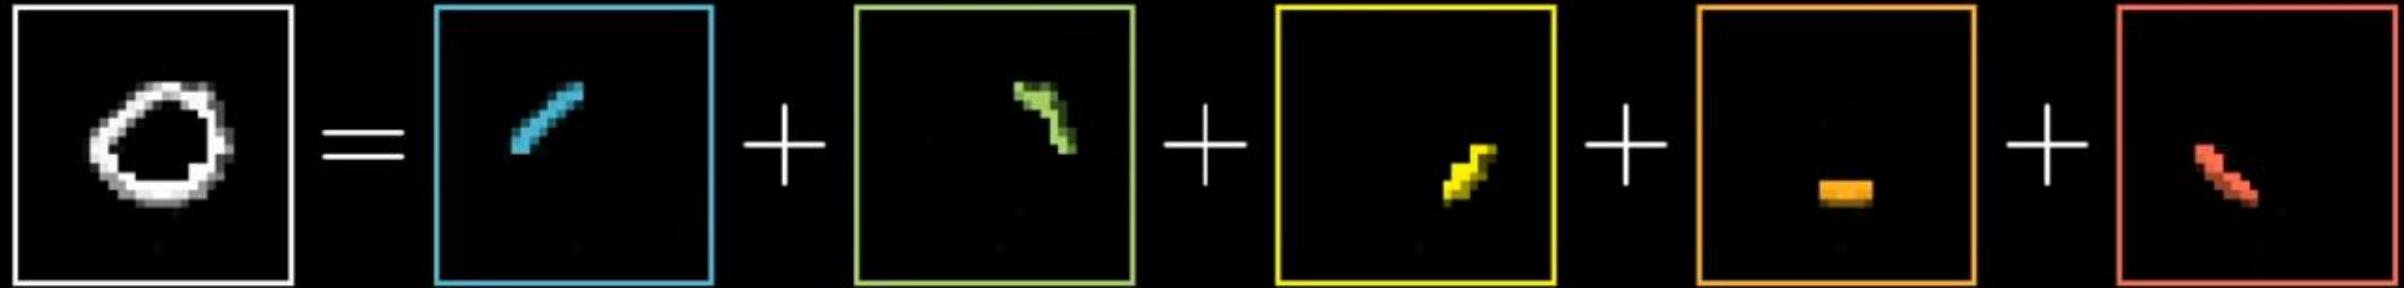


Upper loop neuron...maybe...

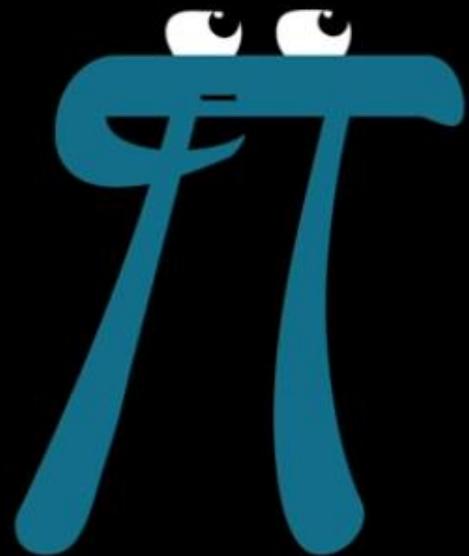
Y los valores de activación de la segunda capa oculta indican con qué probabilidad se han reconocido esos trazos más básicos.

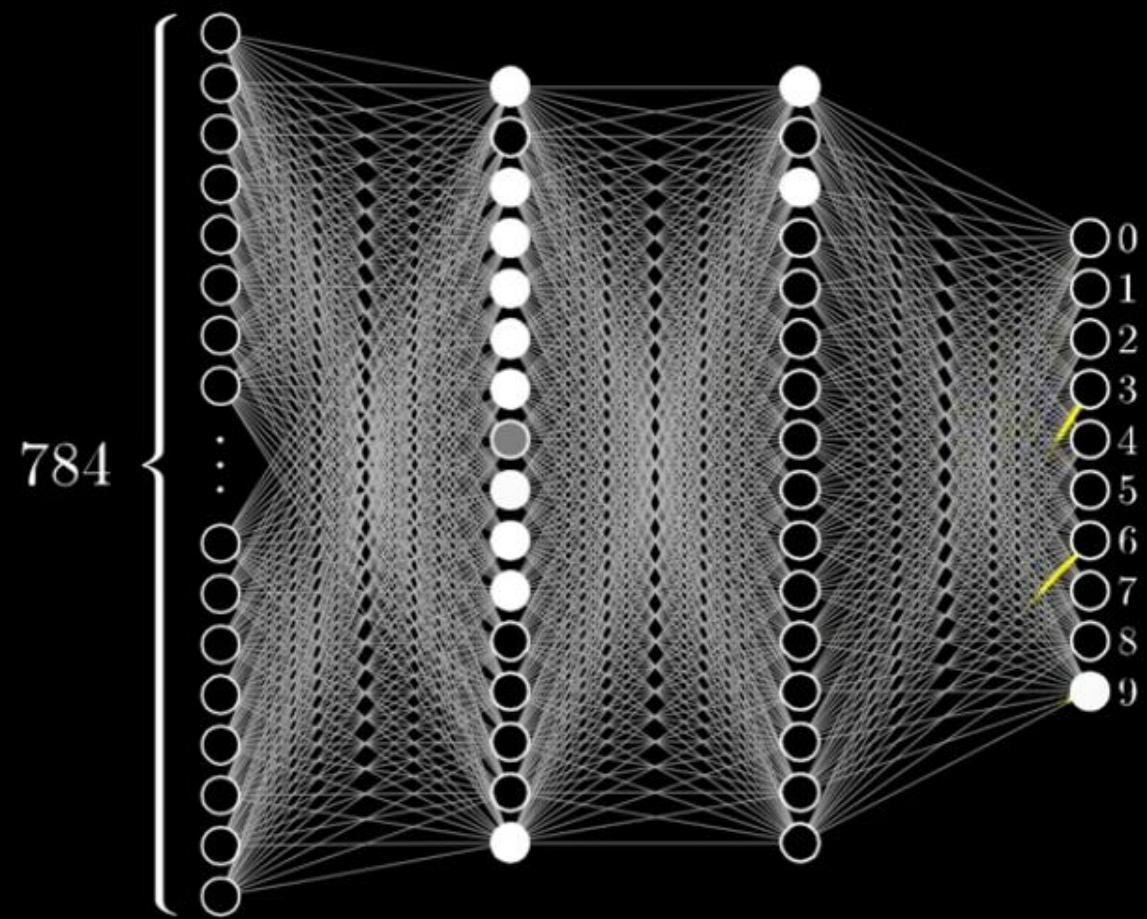
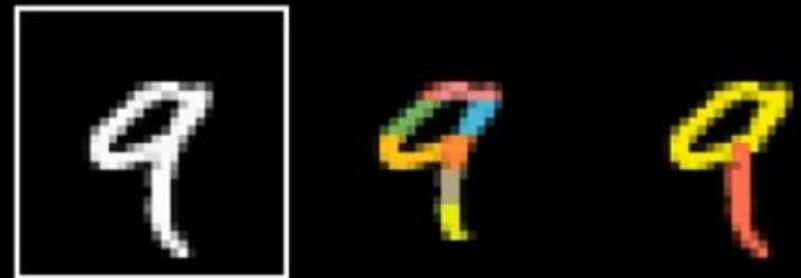


¿Pero no es el mismo problema?
Antes teníamos que reconocer
trazos de números, pero ahora
temenos que reconocer trazos
básicos.
¿Cómo?



Descomponemos los trazos básicos, en trazos aún más básicos, y los utilizamos en la primera capa oculta.

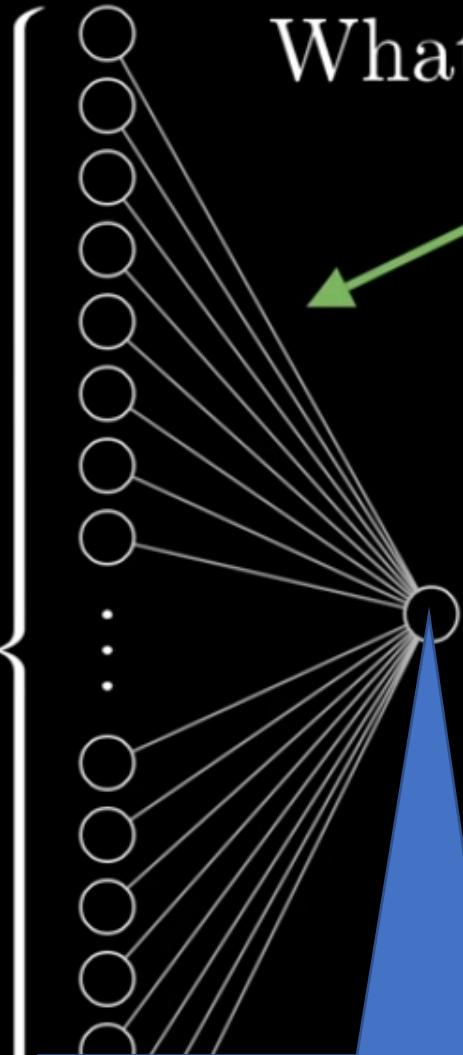




¿Nos estás tomando el pelo?
El problema sigue siendo el
mismo: Reconocer trazos
¿Cómo?

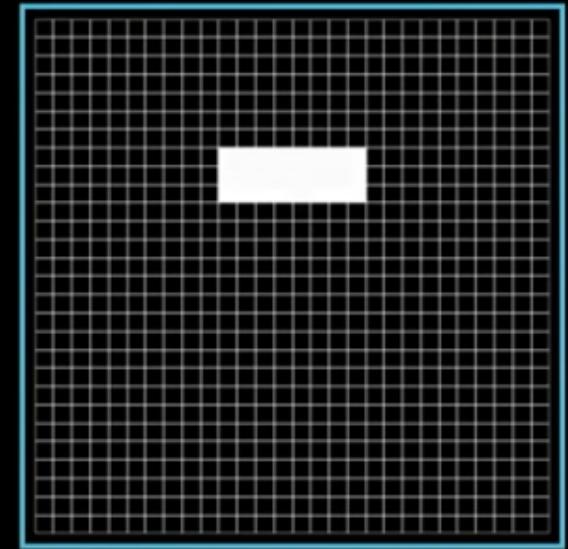
What parameters should exist?

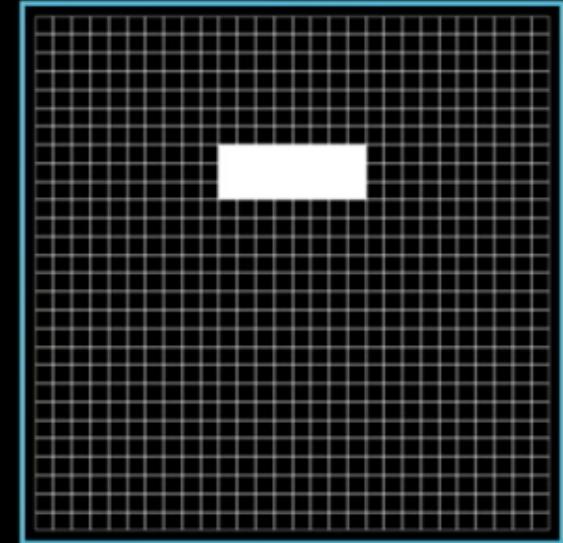
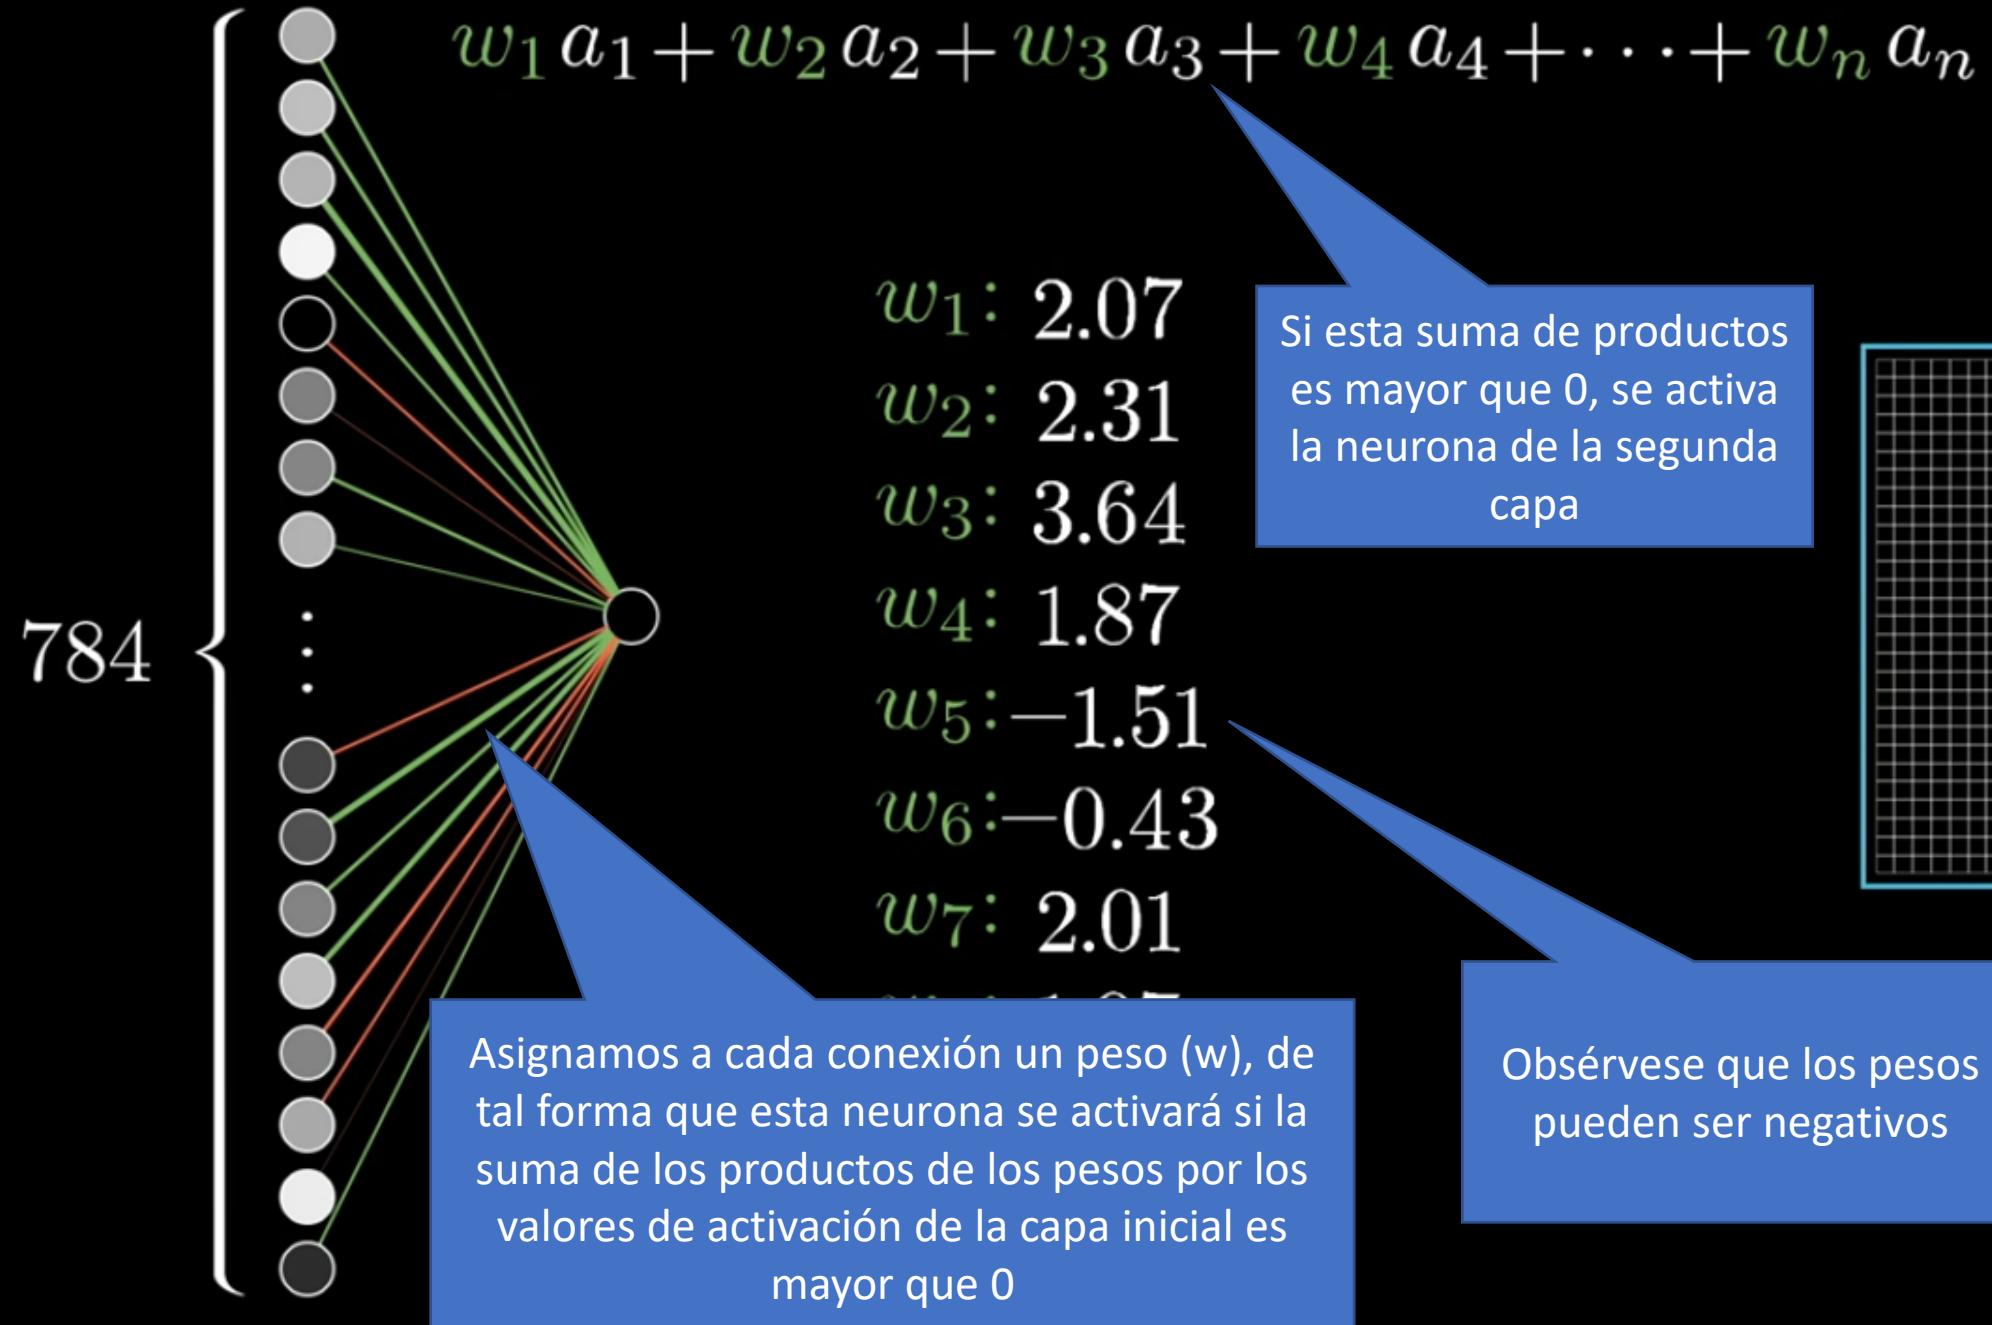
784



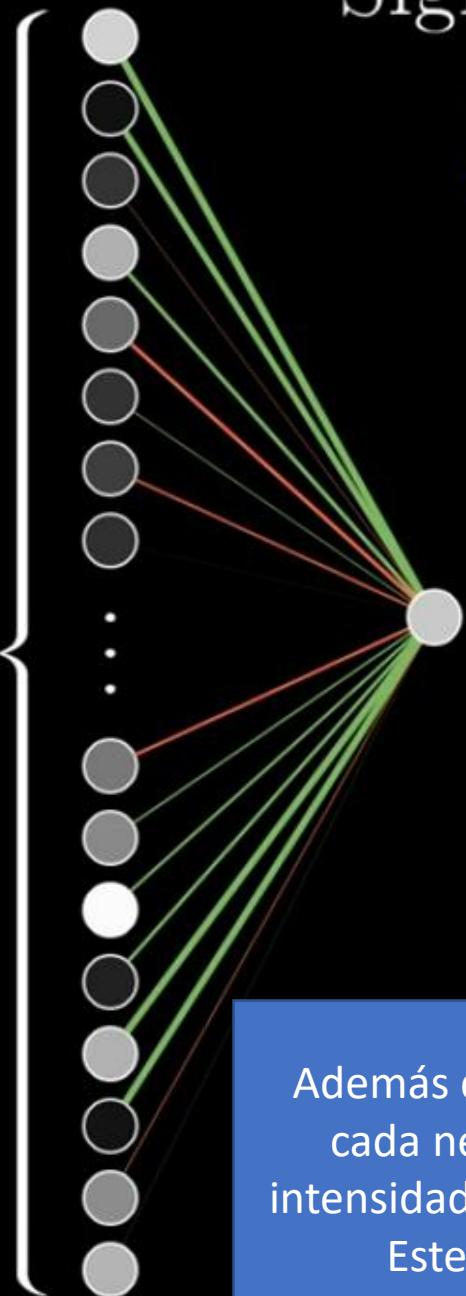
Supongamos que esta
neurona es la
responsable de detectar
este tipo de trazo básico.

$p_1: 0.00$
 $p_2: 0.00$
 $p_3: 0.00$
 $p_4: 0.00$
 $p_5: 0.00$
 $p_6: 0.00$
 $p_7: 0.00$
 $p_8: 0.00$
:





784



Además de los pesos de las conexiones, a
cada neurona se le asigna un valor de
intensidad que debe superar para activarse.
Este valor se llama bias o sesgo.

Sigmoid

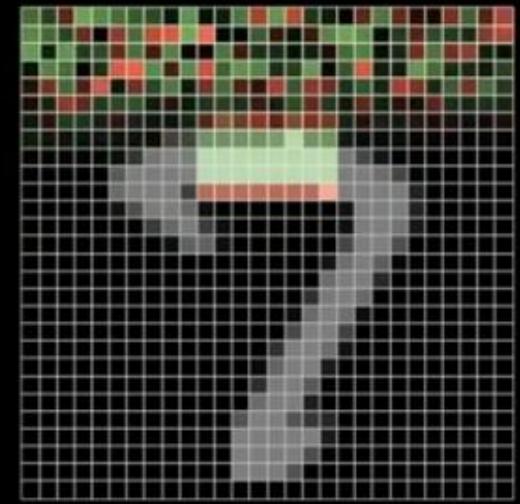


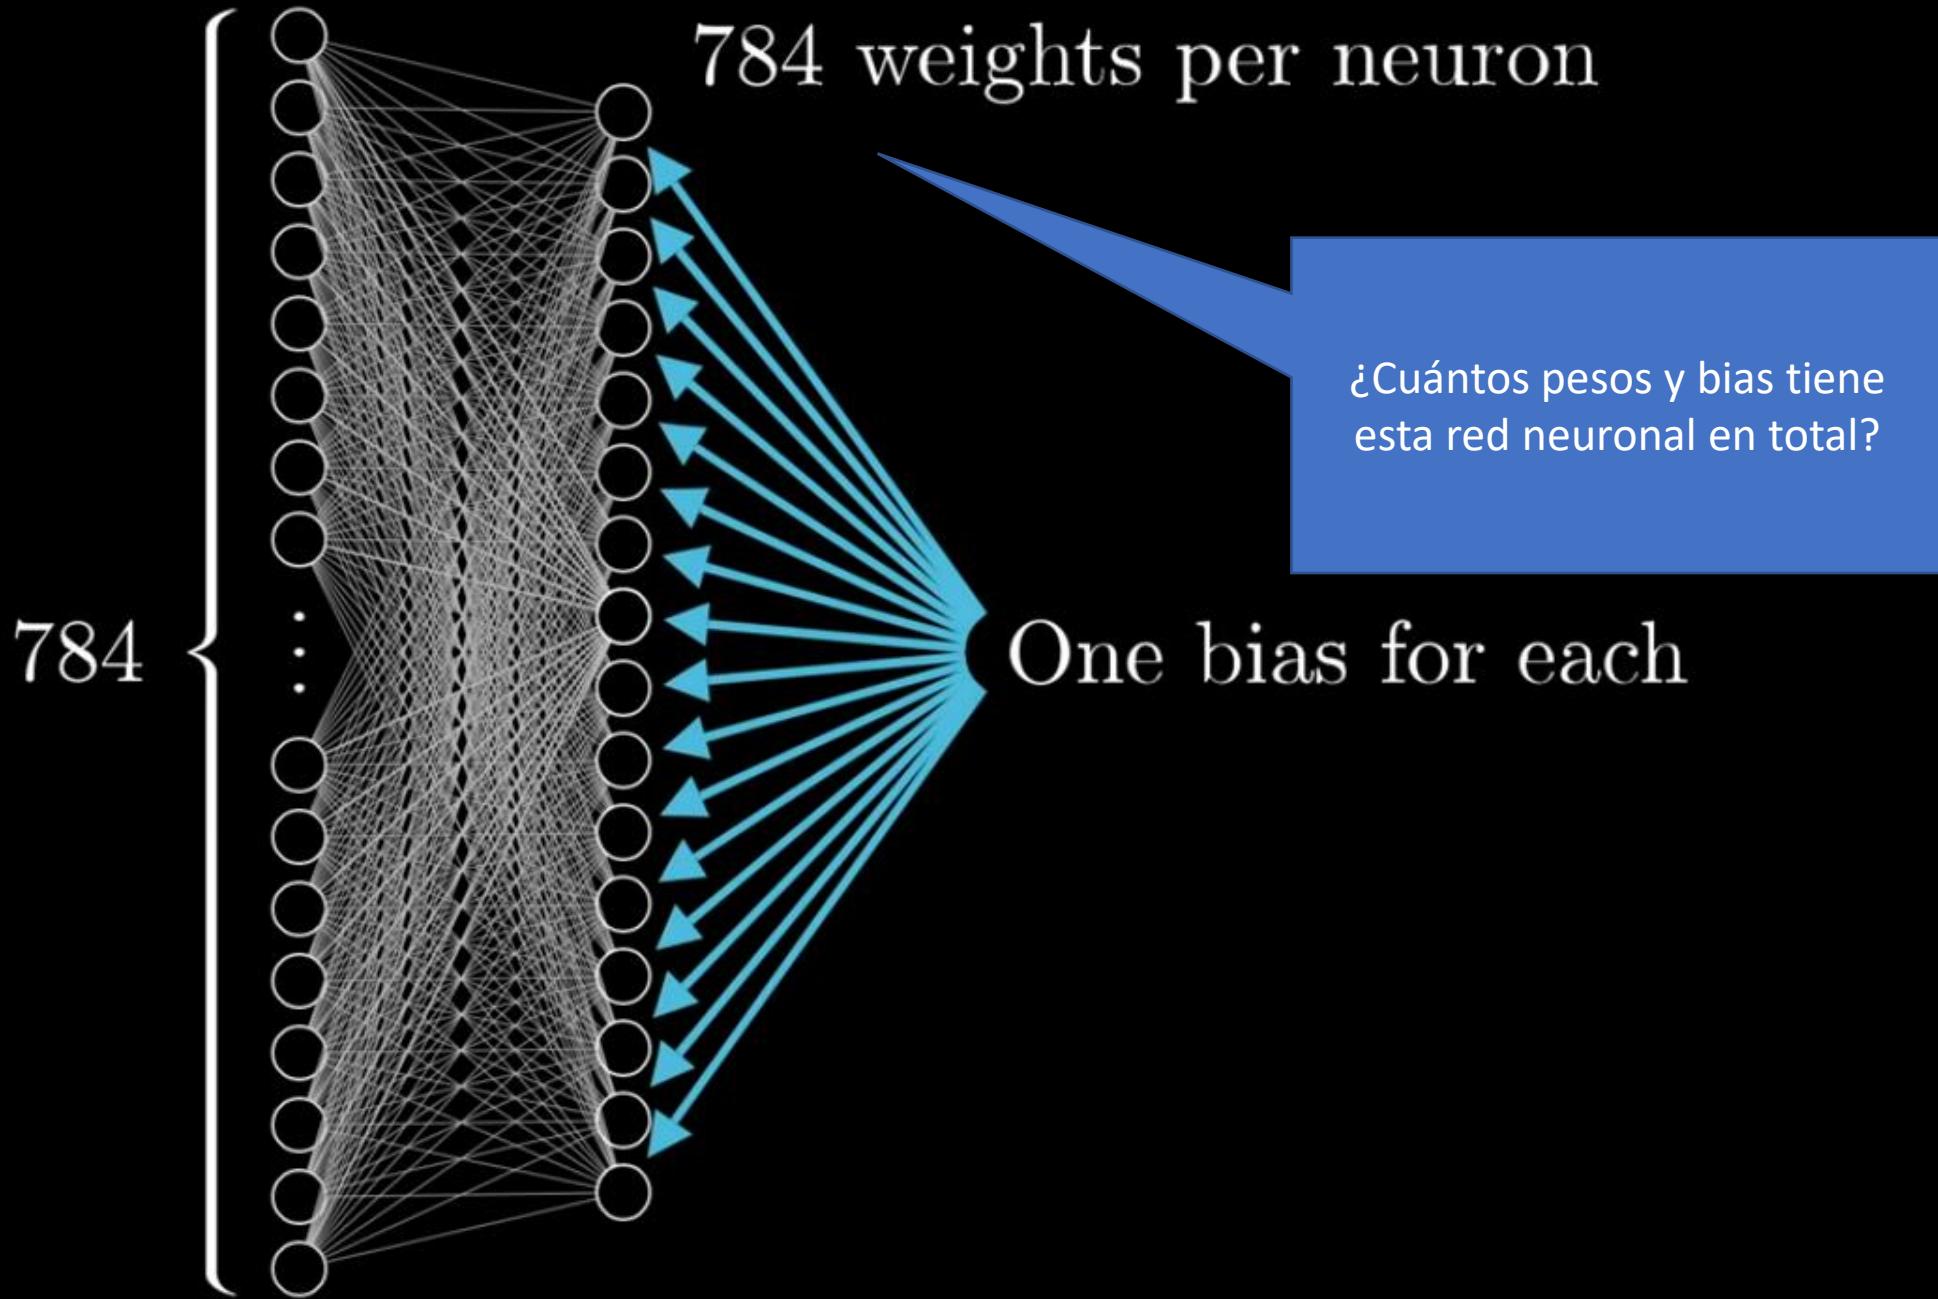
How positive is this?

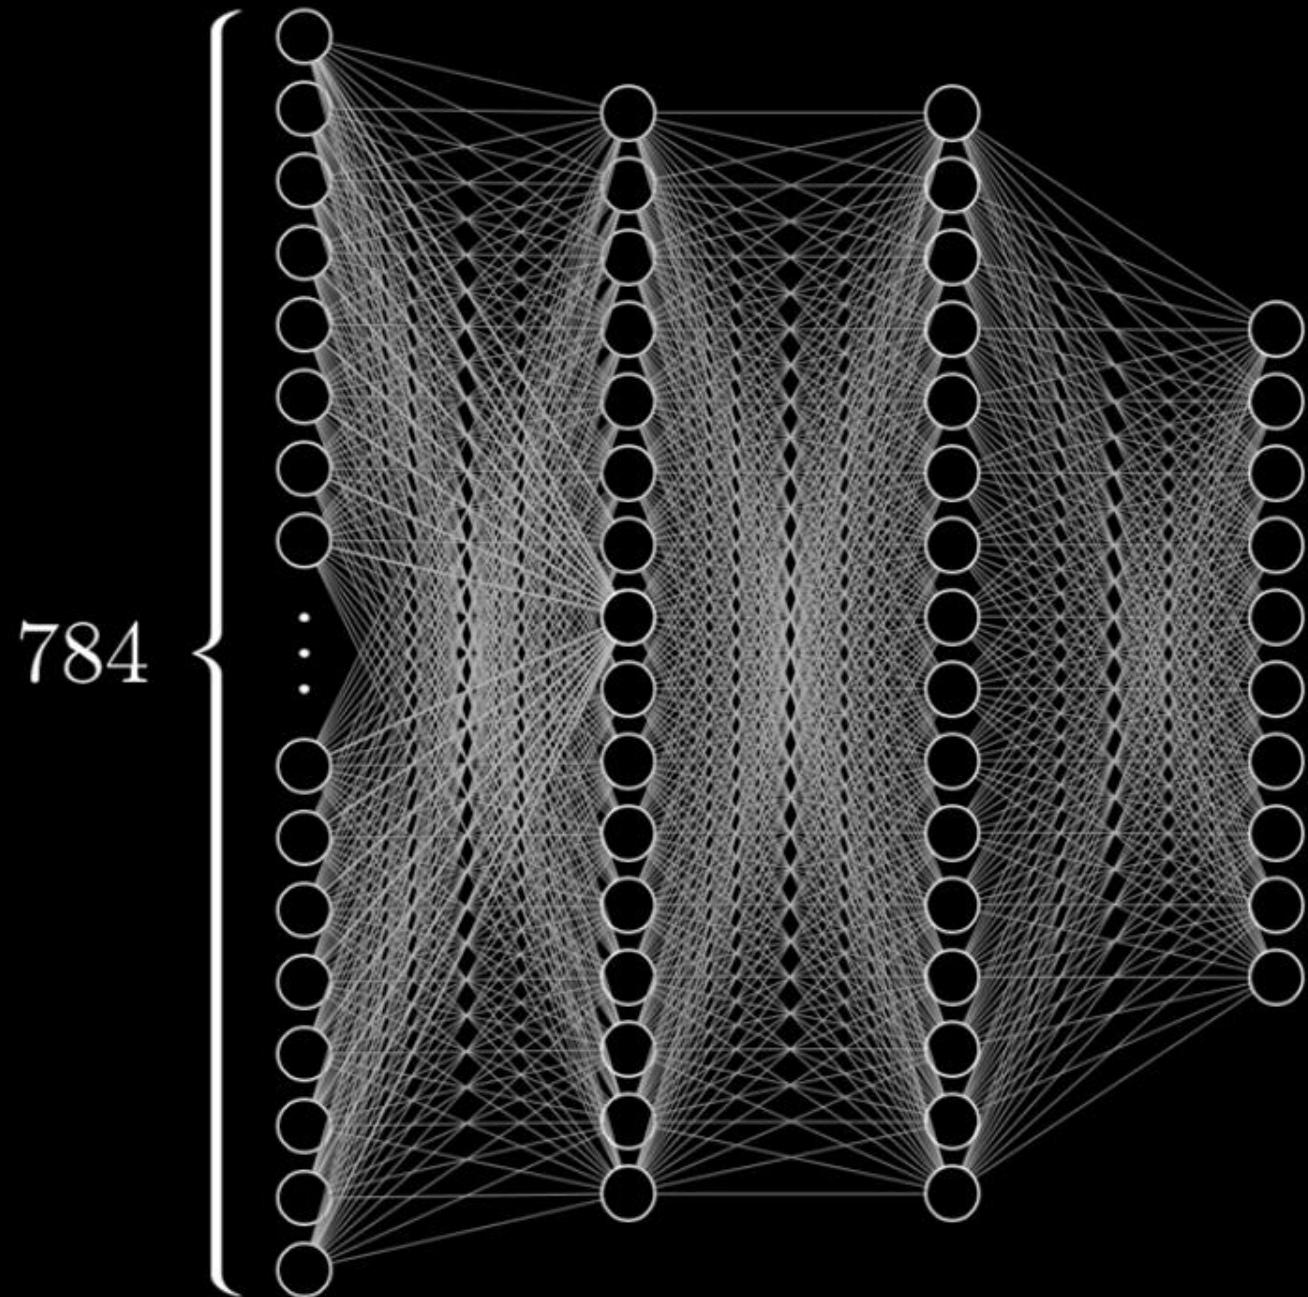
$$\sigma(w_1a_1 + w_2a_2 + w_3a_3 + \dots + w_na_n - 10)$$

“bias”

Only activate meaningfully
when weighted sum > 10







$784 \times 16 + 16 \times 16 + 16 \times 10$
weights

$16 + 16 + 10$
biases

13002

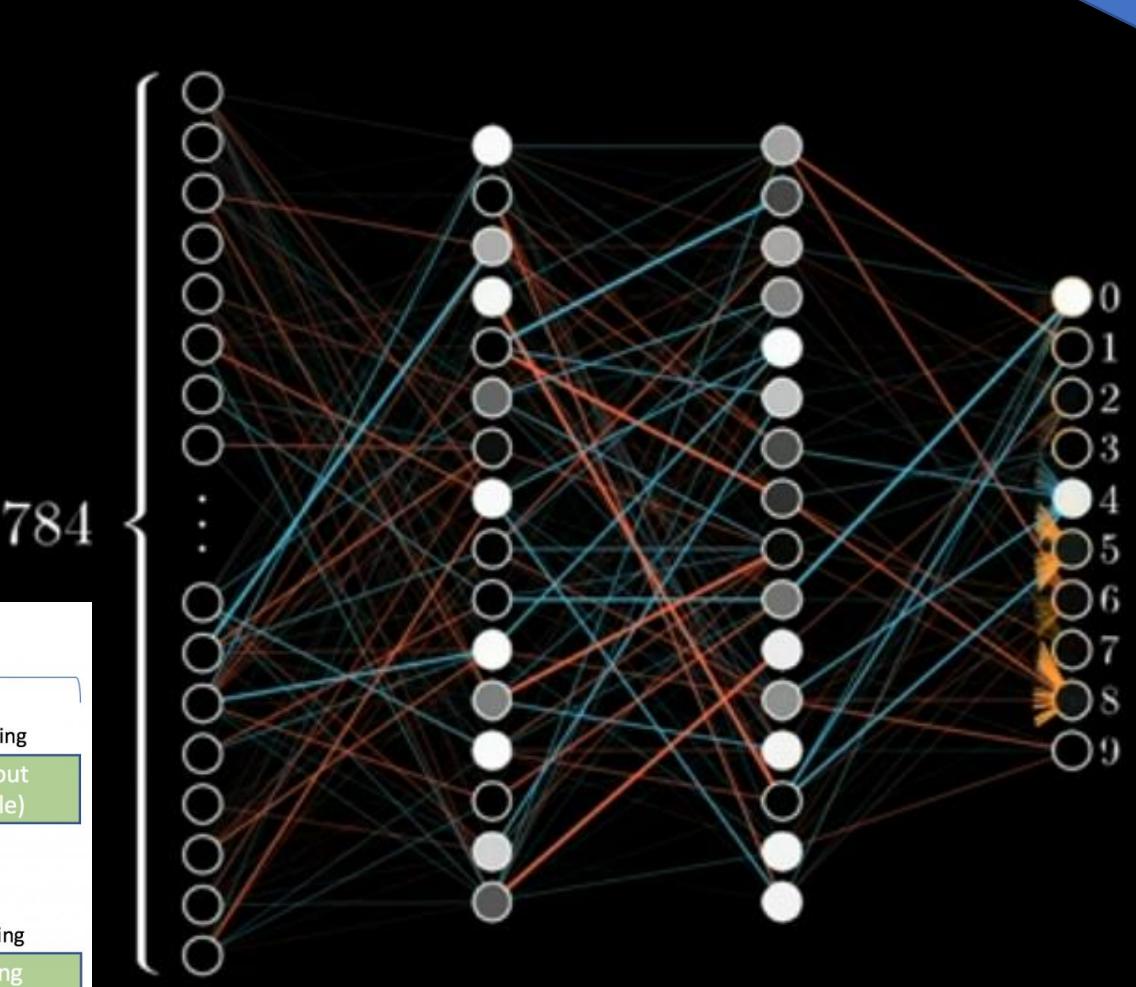
El conjunto de pesos + bias
se denomina "Parámetros
del modelo", y se
determinan mediante el
entrenamiento.



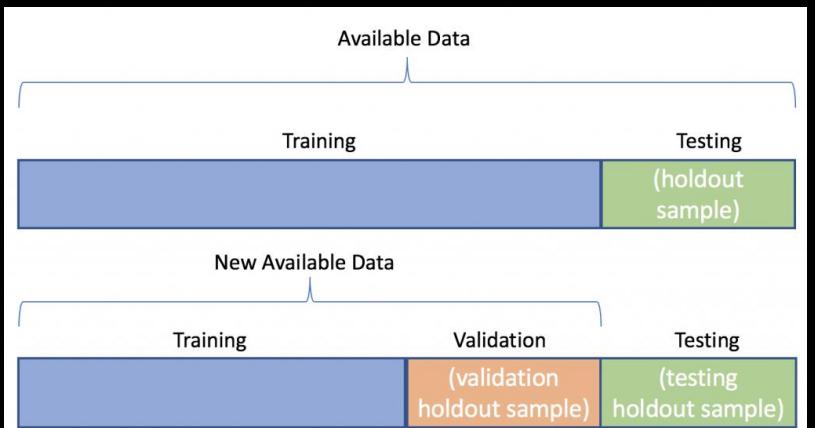
Training in progress. . .



En el entrenamiento se utiliza el **training set** para determinar los parámetros (pesos y bias), de forma que el número de aciertos sea máximo.



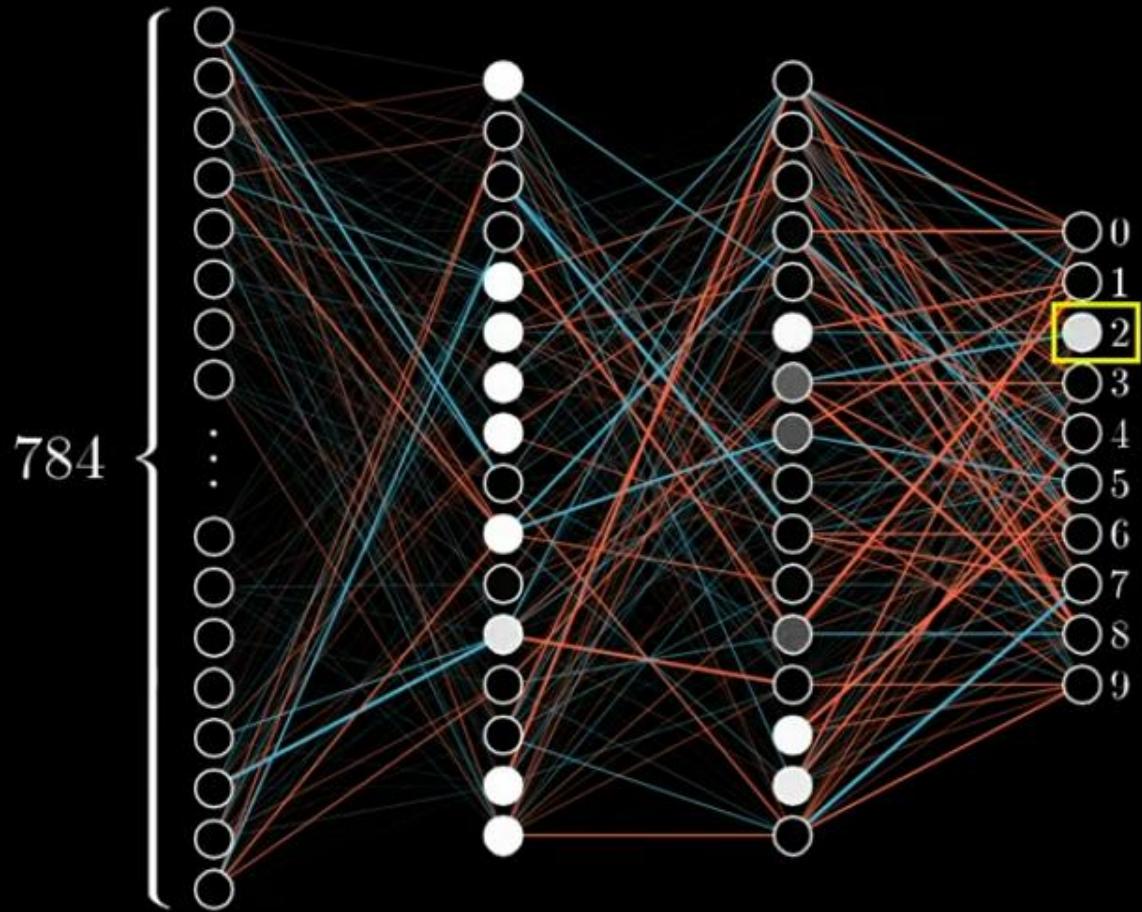
Si el entrenamiento produce resultados malos, podemos estar ante un underfitting (modelo inadecuado).



Testing data



Guess → 2



$$\frac{\text{Number correct}}{\text{total}} = \frac{76}{78} = 0.974$$

Al terminar el entrenamiento, se usa el **testing set** para probar la eficiencia del modelo con datos que no ha "visto" antes. Si la eficiencia es baja, podemos estar ante un overfitting.

Esta métrica se llama exactitud (accuracy) y puede ser engañosa si el dataset no está equilibrado (si hay más muestras de un tipo que de los demás)



Aprendizaje supervisado

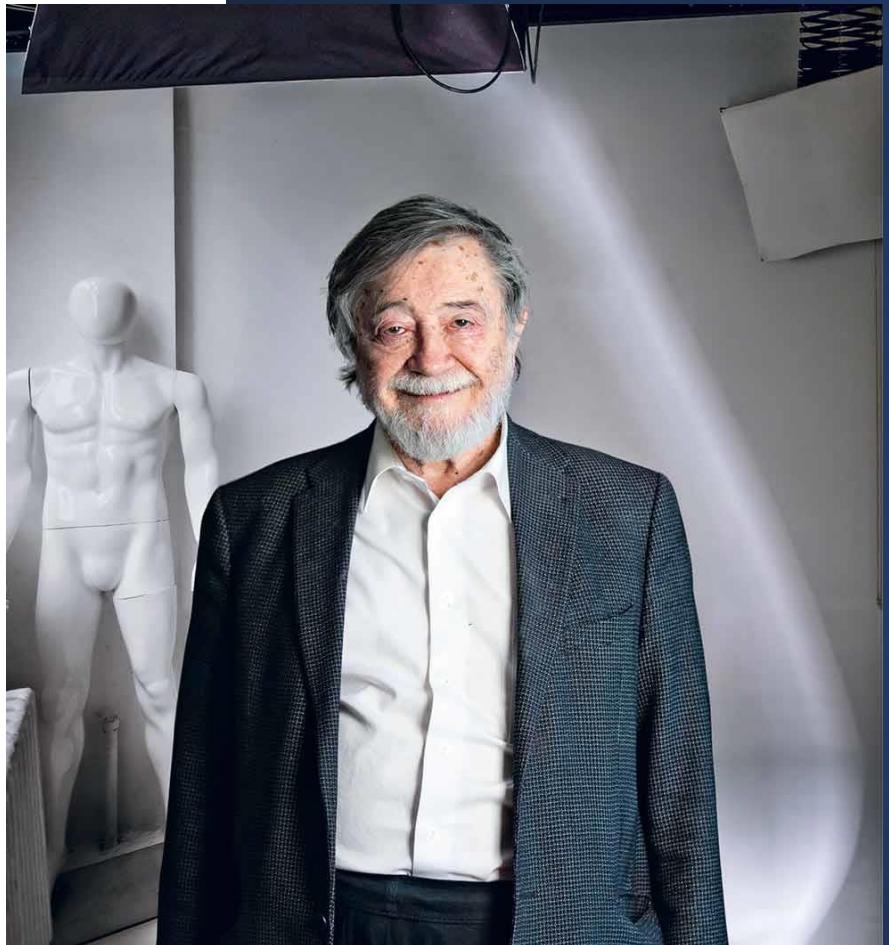




Inceptionismo

Material de reflexión

- Judea Pearl – Premio Turing
 - ¿Puede enamorarse una AI?
 - ¿Qué nos distingue de la AI?
 - El hardware es distinto pero el software es el mismo
 - Quizás el miedo a la muerte, pero quizás ni siquiera eso
 - La escalera de la causalidad
 - **Observar**
 - Hoy las AI aprenden como los animales, por asociación, pero no por causalidad.
 - El gallo canta, va a amanecer
 - Pero el canto del gallo no es la causa de que amanezca
 - **Hacer** (*Si me tomo una aspirina, ¿se me quitará el dolor de cabeza?*)
 - Todas las criaturas pueden ver lo que existe. Nuestro don es tener la capacidad de 'ver' lo que podría haber existido
 - **Imaginar** (*¿Ha sido realmente la aspirina lo que me ha quitado el dolor de cabeza?*)
 - Si Juan bloquea la salida de incendios de un edificio y María fallece por no poder acceder a ella, ¿Juan es responsable legal de su muerte, aunque no encendiera el fuego? → La AI podrá responder estas preguntas



Conceptos esenciales

Aprendizaje

- Supervisado
- No supervisado
- Por refuerzo

Redes neuronales

- Capas
- Features o características
- Neuronas
- Valor de activación
- Conexiones
- Parámetros (pesos y bias)
- Entrenamiento y prueba
 - Training set y Test set
 - Underfitting y overfitting

Edge Impulse

edgeimpulse.com

- usuario01@ttnmad.org / ttnmadorg01
- usuario02@ttnmad.org / ttnmadorg02
- usuario03@ttnmad.org / ttnmadorg03
- usuario04@ttnmad.org / ttnmadorg04
- usuario05@ttnmad.org / ttnmadorg05

Conectar el dispositivo al data forwarder

- Usamos el Data Forwarder
 - <https://docs.edgeimpulse.com/docs/edge-impulse-cli/cli-data-forwarder>
- En una ventana de comando ejecutamos:
 - `edge-impulse-data-forwarder`

```
C:\WINDOWS\system32\cmd.exe - "node" "C:\Users\juanfe\AppData\Roaming\npm\\node_modules\ed
Microsoft Windows [Versión 10.0.19043.1645]
(c) Microsoft Corporation. Todos los derechos reservados.

C:\Users\juanfe>edge-impulse-data-forwarder
Edge Impulse data forwarder v1.14.8
WARN: You're running an outdated version of the Edge Impulse CLI tools
      Upgrade via `npm update -g edge-impulse-cli`
Endpoints:
  WebSocket: wss://remote-mgmt.edgeimpulse.com
  API:       https://studio.edgeimpulse.com/v1
  Ingestion: https://ingestion.edgeimpulse.com

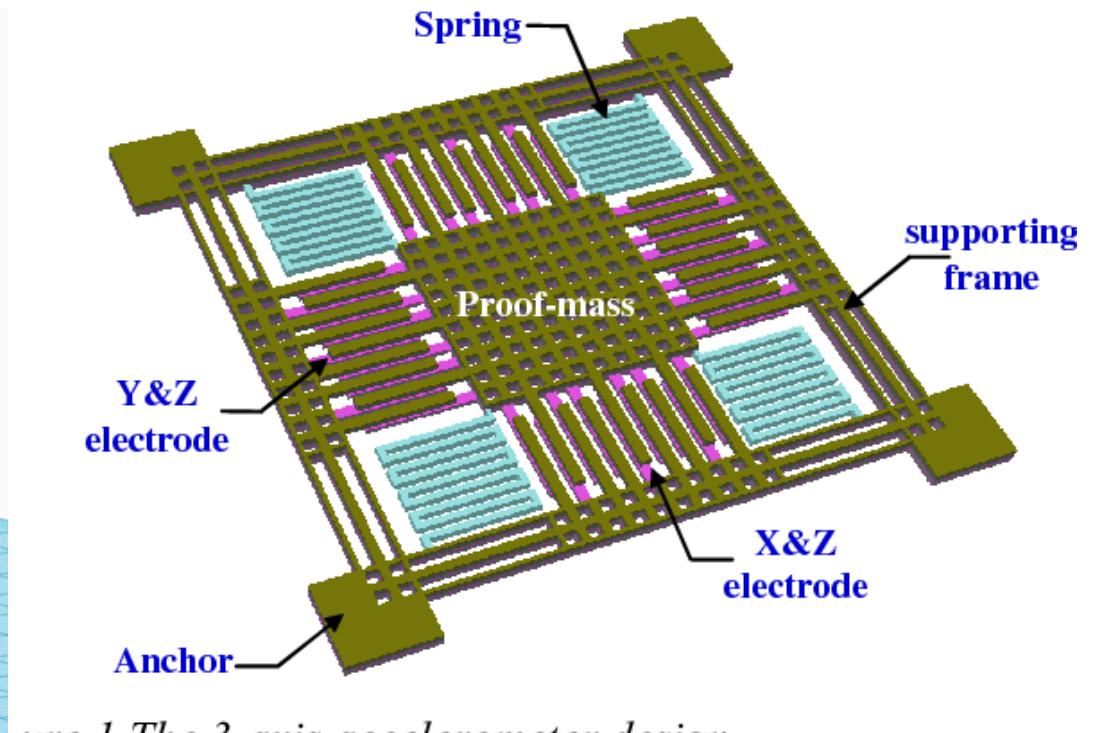
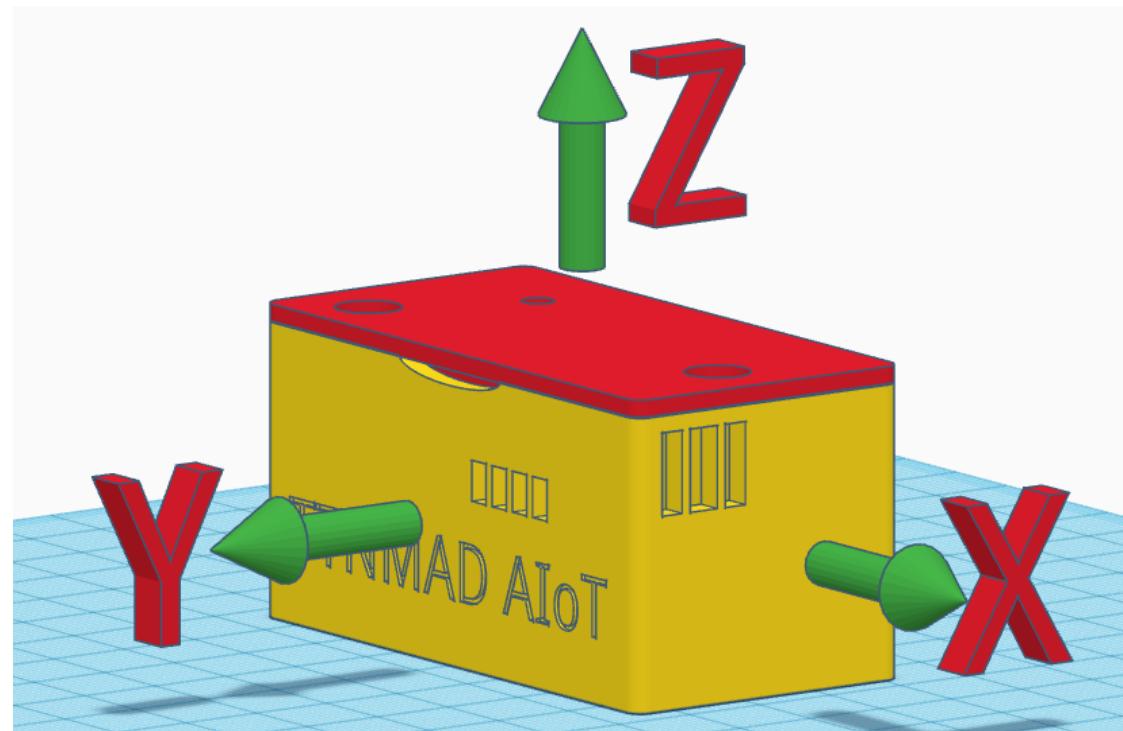
? Which device do you want to connect to? (Use arrow keys)
> COM16 (Microsoft)
  COM15 (Microsoft)
```

Edge Impulse

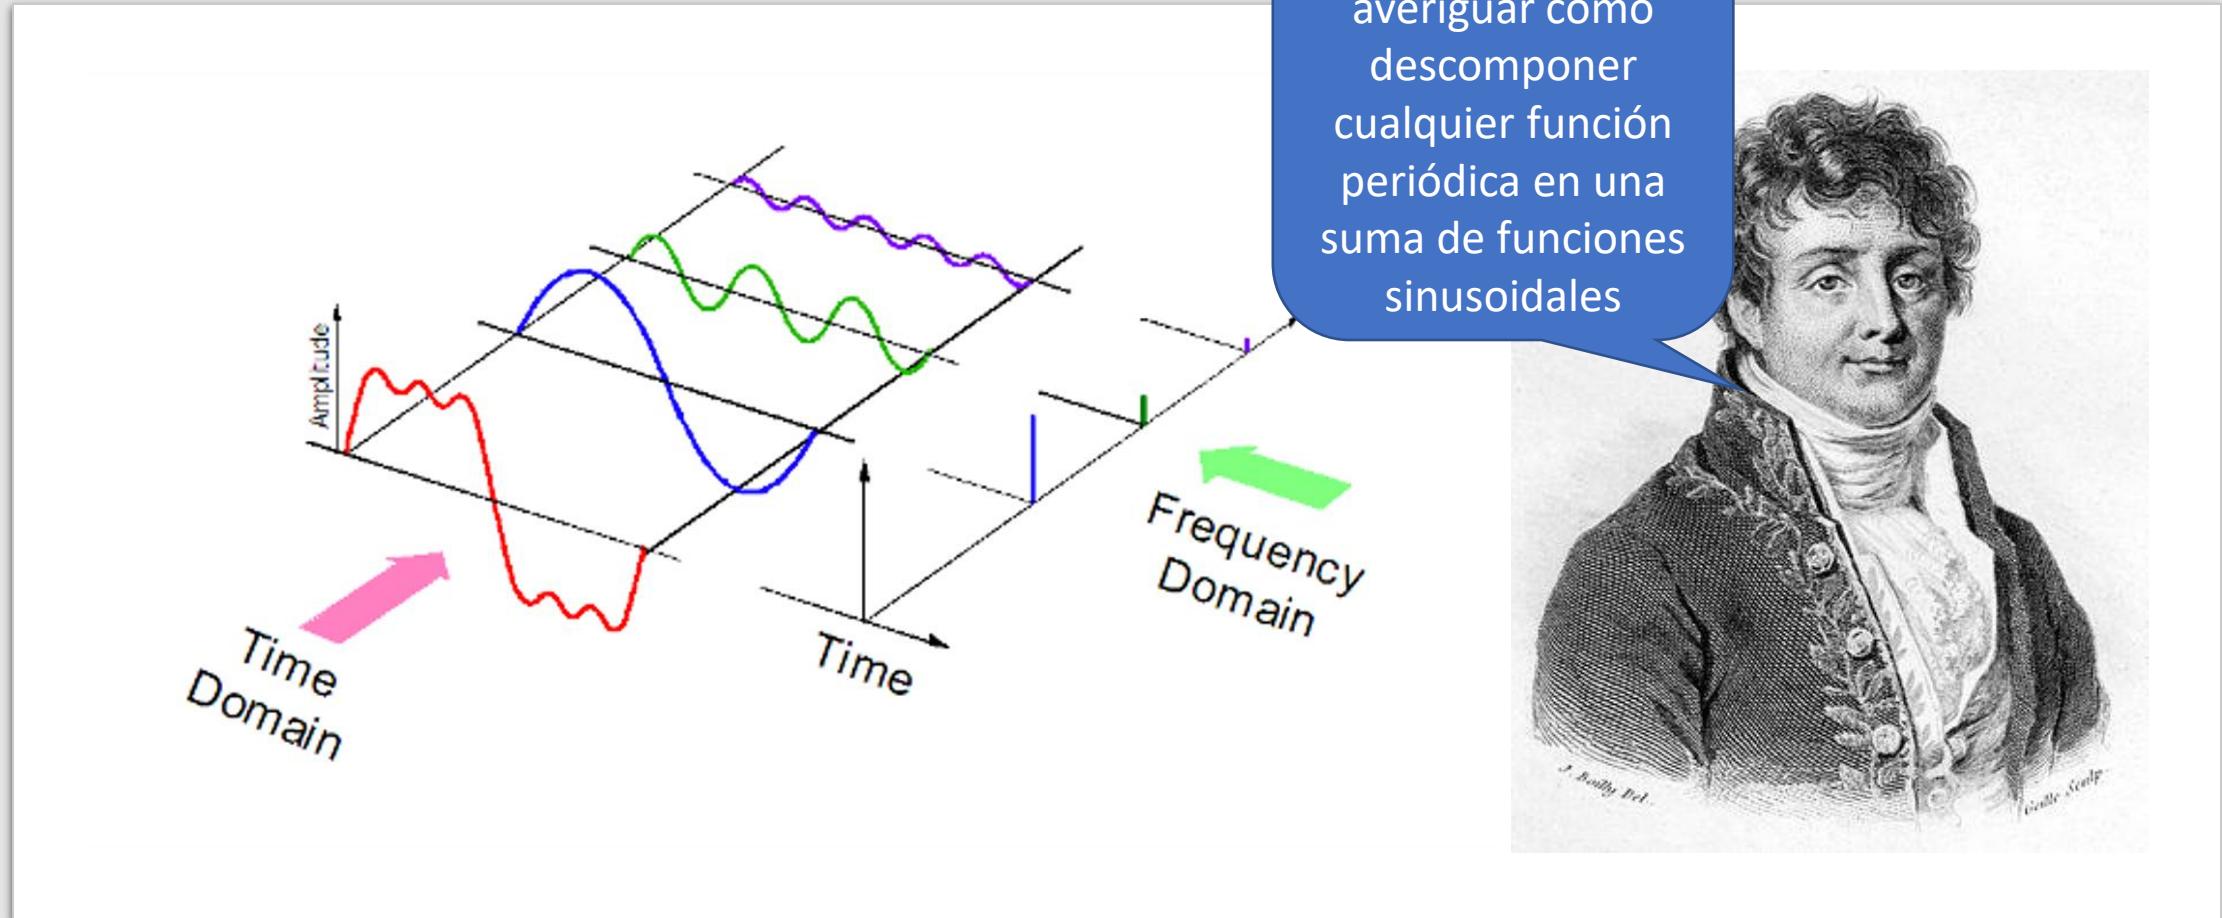
- Crear un proyecto de acelerómetro
- Conectar el dispositivo mediante el data forwarder
 - \$ edge-impulse-data-forwarder
- Obtener 5 muestras de cada clase: Aparecum, Specialis Revelio, y Pausa
 - Ventana 18000 ms (hacer movimiento en 15, 12, 9, 6 y 3 segundos)
 - Hacer Split de cada muestra tras tomarla con duración de 2500ms
- Balancear training/test set
- Crear el impulso
 - Obtener las features con Spectral features (Windows size 2500 y Window increase 100)
 - Comprobar que muestras con la misma etiqueta tienen features muy similares
 - Entrenar con 1, 2 y 100 ciclos para ver la diferencia de precisión (0.3, 0.4 y 0.98)
- Hacer Live Classification (sample length 2500) y comentar los resultados
- Añadir un bloque de Detección de anomalías (select suggested axes)



Acelerómetro



Fast Fourier Transform



Impulse

Time series data

Axes: x, y, z

Window size: 2500 ms.

Window increase: 100 ms.

Frequency (Hz): 50

Zero-pad data:

Spectral Analysis

Name: Spectral features

Input axes: x, y, z

Classification (Keras)

Name: NN Classifier

Input features: Spectral features

Output features: 2 (NO, SI)

Output features

3 (NO, SI, Anomaly score)

Save Impulse

Add a processing block

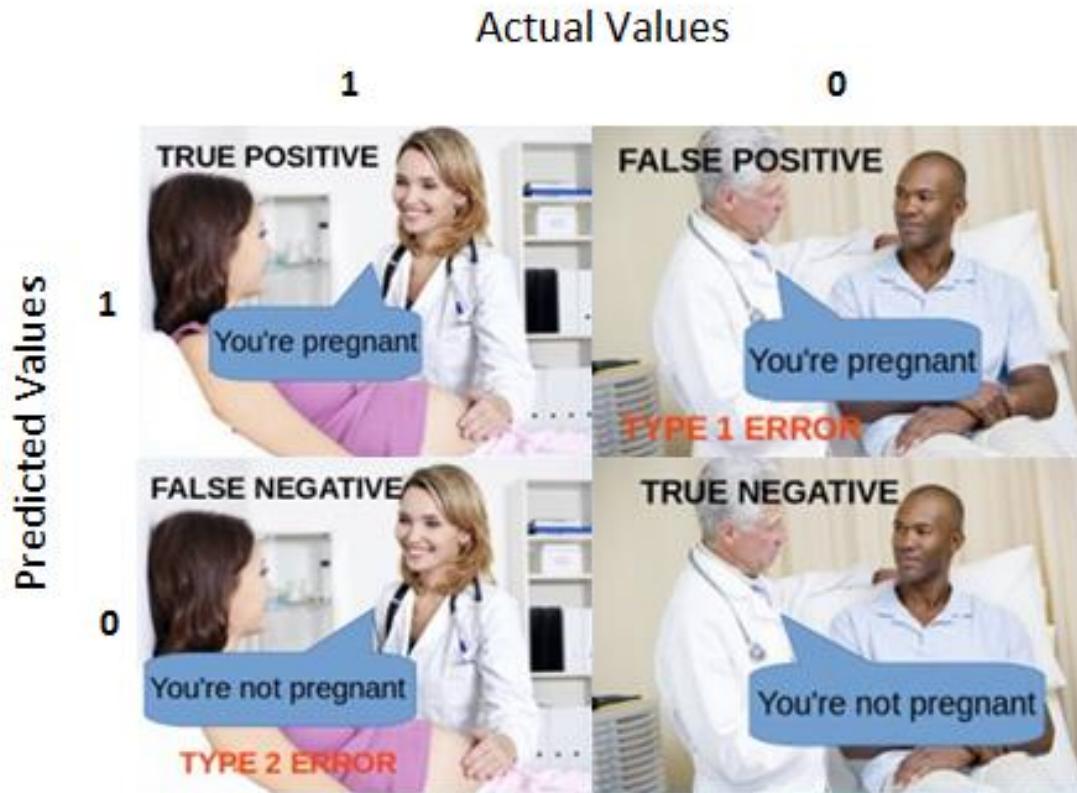
Anomaly Detection (K-means)

Name: Anomaly detection

Input features: Spectral features

Output features: Anomaly score

Matriz de confusión y métricas



		Ground truth		
		+	-	
Predicted	+	True positive (TP)	False positive (FP)	Precision = $TP / (TP + FP)$
	-	False negative (FN)	True negative (TN)	
		Recall = $TP / (TP + FN)$		Accuracy = $(TP + TN) / (TP + FP + TN + FN)$

Exhaustividad

Exactitud
¡PELIGRO!